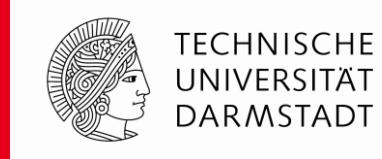


Computer Vision – Erkennung

Visual Computing
Winter Semester 2023-2024



Prof. Dr. A. Kuijper

Mathematical and Applied Visual Computing (MAVC)
Graphisch-Interaktive Systeme (GRIS)
Fraunhofer IGD
Fraunhoferstrasse 5
D - 64283 Darmstadt

E-Mail: office@gris.tu-darmstadt.de
<http://www.gris.tu-darmstadt.de>
<https://www.mavc.tu-darmstadt.de>

Semesterplan



Datum	
20. Okt	Einführung + <u>Visual Computing</u>
27. Okt	<u>Wahrnehmung</u>
03. Nov	Objekterkennung und Bayes
10. Nov	Fourier Theorie
17. Nov	Bilder
24. Nov	Bildverarbeitung
01. Dez	Grafikpipeline & Eingabemodalitäten & VR+AR
08. Dez	Transformationen & 2D/3D Ausgabe
15. Dez	3D-Visualisierung
12. Jan	X3D – 3D in HTML
19. Jan	Informationsvisualisierung
26. Jan	Farbe
02. Feb	User Interfaces + Multimedia Retrieval
11. Feb	Biometrie (?)





Warum Computer Vision?

- Wissenschaft
 - Grundlagen der Wahrnehmung: Wie sehen WIR (Menschen)?
 - Erforschen eines computergestützen Modells des menschlichen Sehens
- Ingenieurwesen
 - Wie baut man Systeme, die die Welt erkennen?
 - Lösen realer Anwendungsfälle: Autos, die Fußgänger erkennen
- Anwendungsgebiete
 - Medizinische Bildverarbeitung (Diagnosen unterstützen, Visualisierung)
 - Überwachung (an Flughäfen, Bahnhöfen, ...)
 - Unterhaltung (kamerabasierte Spiele [EyeToy, Kinect, ...])
 - Computergrafik (bildbasiertes Rendering, Computer Vision zur Unterstützung realistischer Grafik)
 - ...

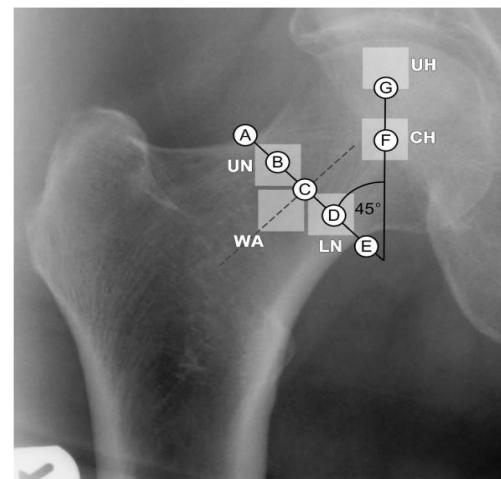


Einige Anwendungen

- Erkennung von Nummernschildern
 - London Congestion Charge („Staugebühr“)
 - [http://www.cclondon.com/
imagingandcameras.html](http://www.cclondon.com/imagingandcameras.html)
 - [http://en.wikipedia.org/wiki/
London_congestion_charge](http://en.wikipedia.org/wiki/London_congestion_charge)



- Überwachung
 - Gesichtserkennung
 - Flughafensicherheit
 - Tracking von Menschen
 - Scannen von Gepäck



- Medizinische Bildverarbeitung
 - (Halb) automatische Segmentieren und Auswerten von Bildern

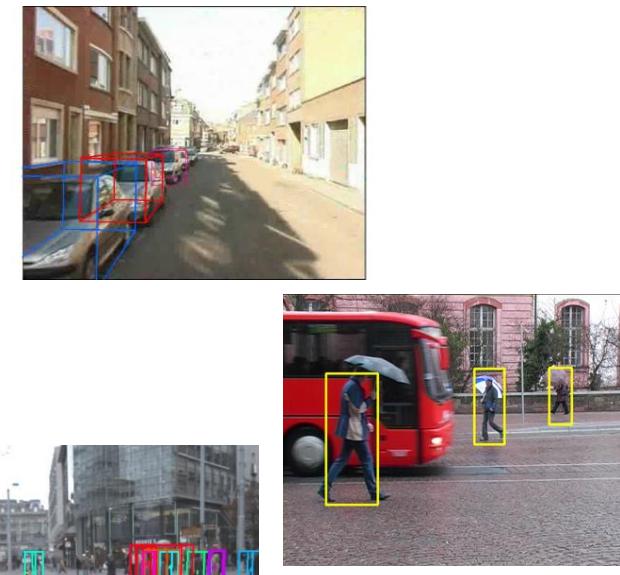
Einige Anwendungen

■ Automobilindustrie

- Heute schon Produkt (bzw. produktreif):
 - Warnung bei Spurwechsel
 - Warnungen bezüglich des toten Winkels
 - Einparkhilfe
 - Warnungen kurz vor einem Zusammenstoß sowie automatisches Bremsen
 - ...



- In naher Zukunft:
 - Bessere Detektion von Fußgängern
 - Wetterkonditionen
 - ...



Autonomes Fahren: <https://dart-racing.de/>



TECHNISCHE
UNIVERSITÄT
DARMSTADT



Autonomes Segeln: <https://www.st-darmstadt.de/>



TECHNISCHE
UNIVERSITÄT
DARMSTADT





Überblick

■ Computer Vision

- **Objekterkennung und Objektdetektion als Fallbeispiel**
- **Motivation heutiger Ansätze**

■ Bayes Decision Theory

- Verwendung von Merkmalen zur Objekterkennung
- Naive Bayes Klassifikator

■ Gesichtsdetektion

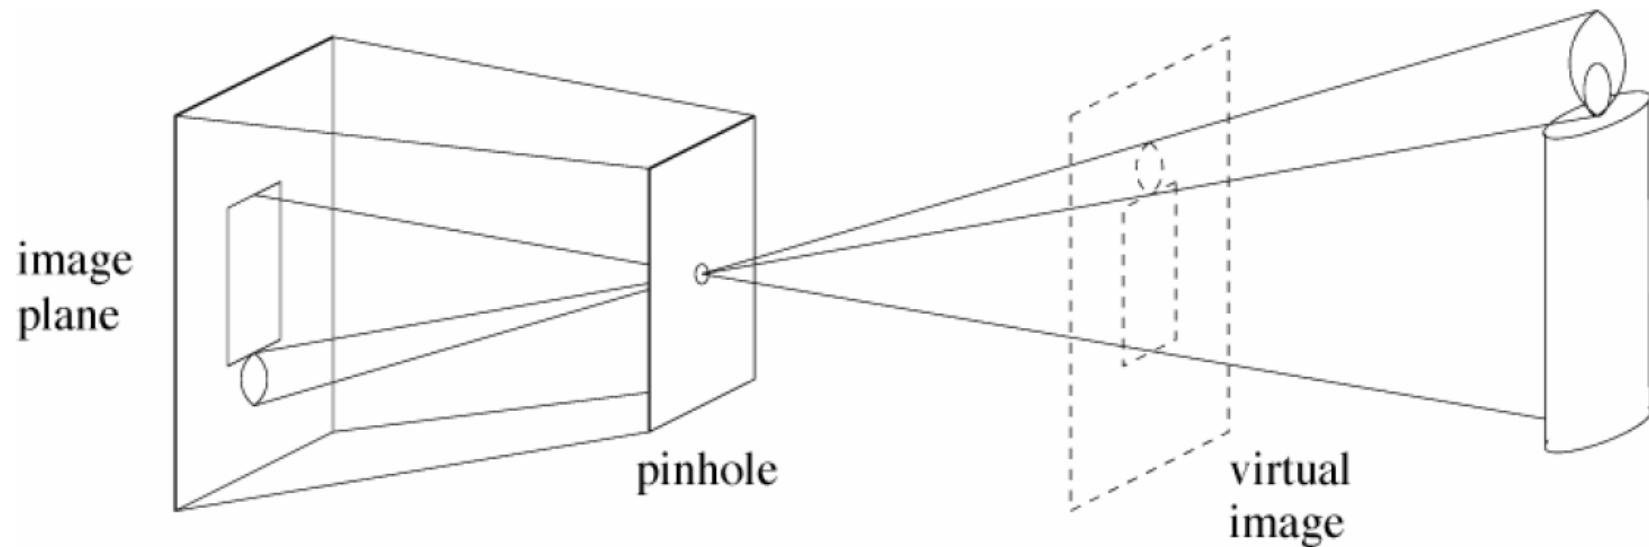
- Schneiderman & Kanade: Naive Bayes Klassifikator
de facto einer der erfolgreichsten Verfahren

■ Diskussion und Ausblick

Lochkamera (Modell)



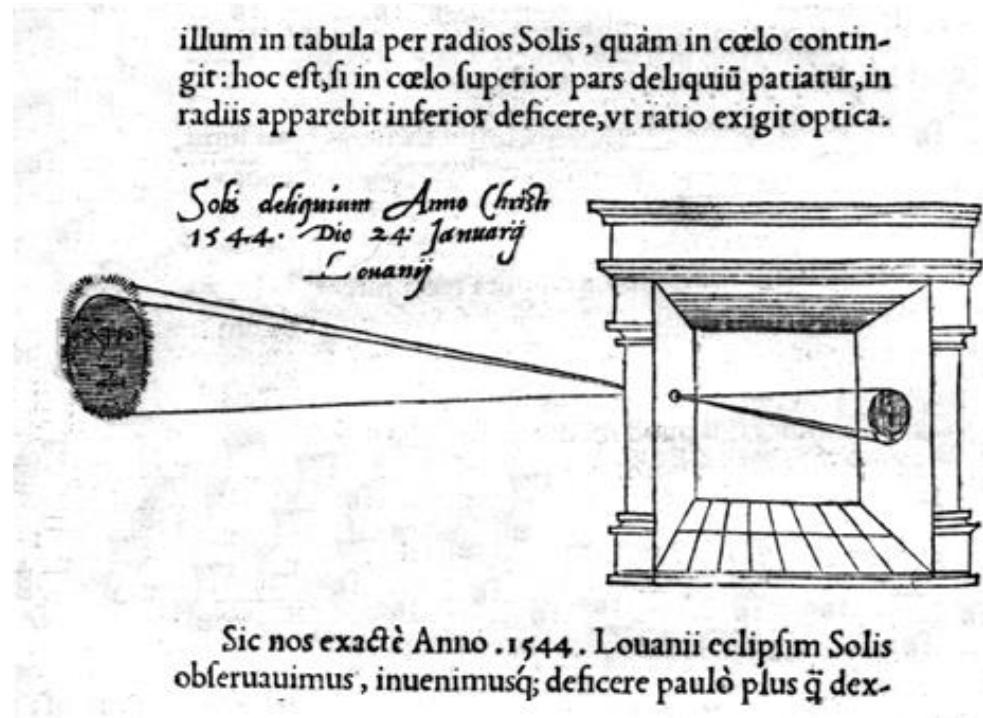
- (Einfaches) Standardmodell und abstraktes Modell
 - Kasten mit einem kleinen Loch



Camera Obscura

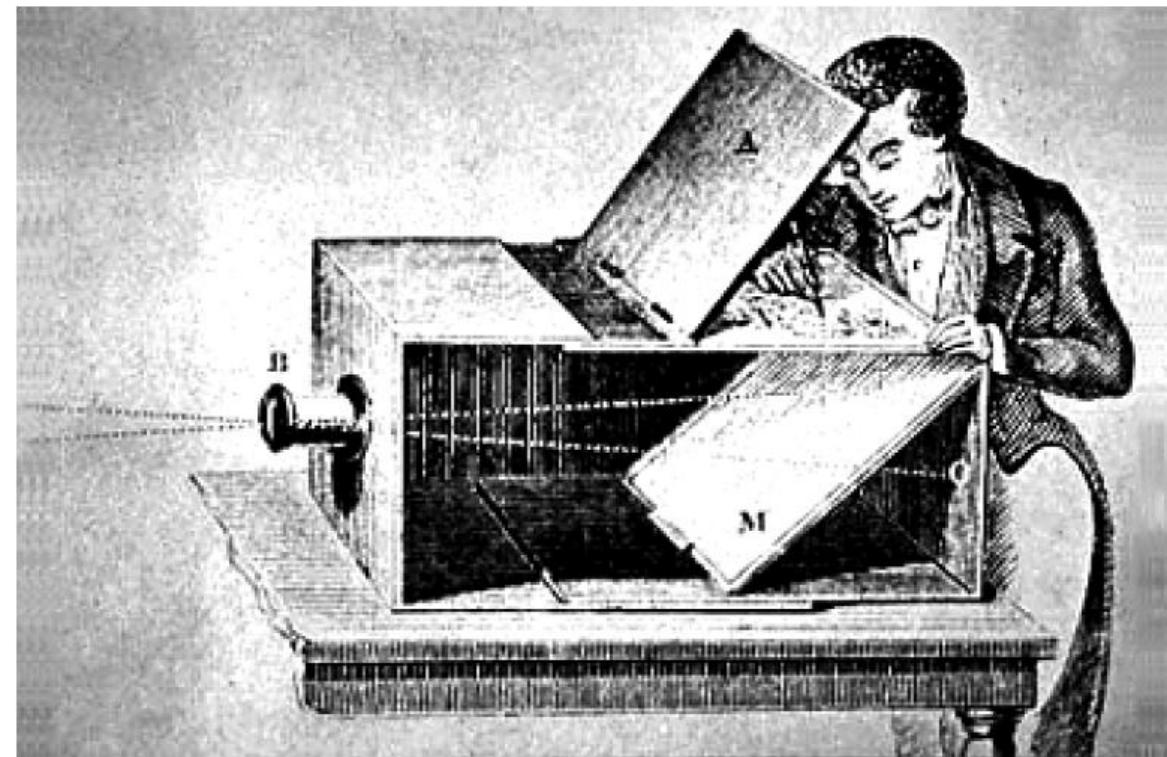
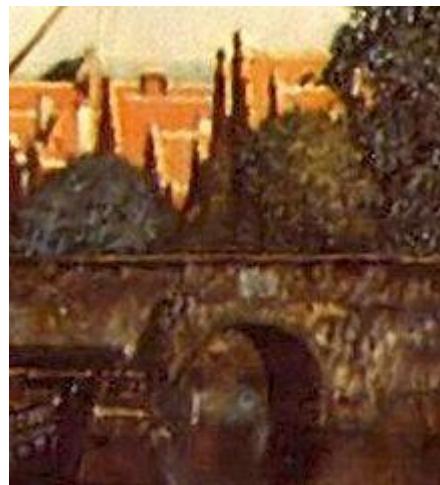
- Um 1519, Leonardo da Vinci (1452 - 1519)
 - http://de.wikipedia.org/wiki/Camera_obscura

► “when images of illuminated objects ... penetrate through a small hole into a very dark room ... you will see [on the opposite wall] these objects in their proper form and color, reduced in size ... in a reversed position owing to the intersection of the rays”



Das Prinzip der Lochkamera...

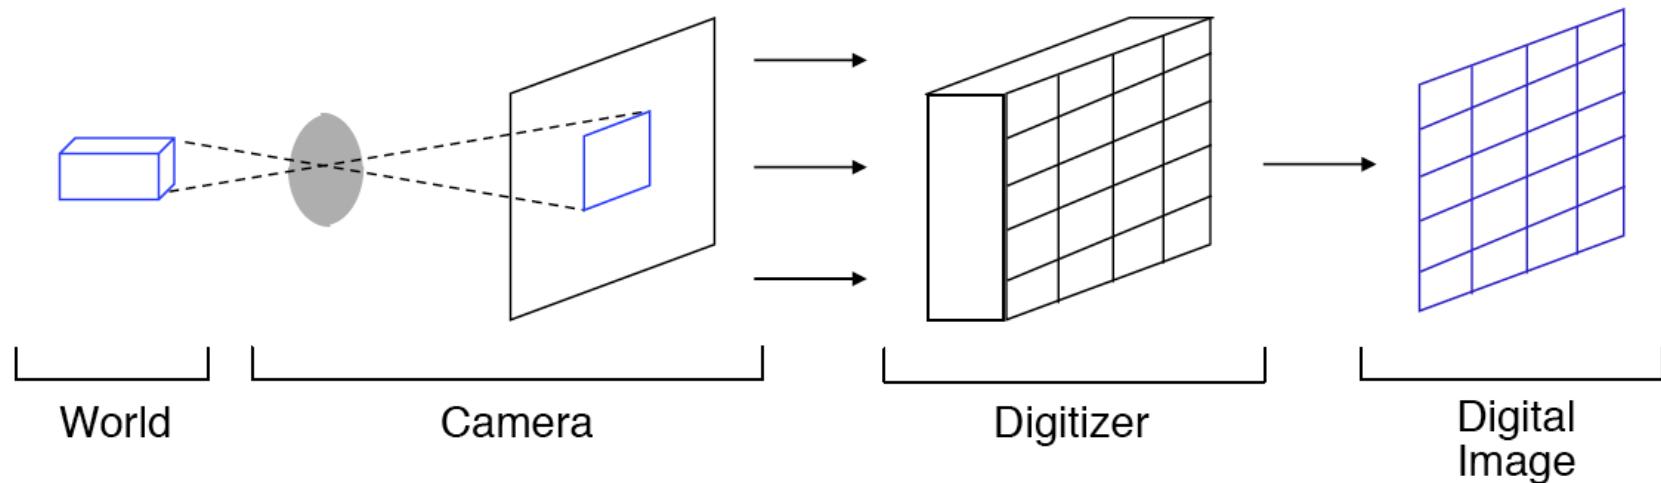
- ...wurde von Künstlern...
 - (z.B. Vermeer
17. Jahrhundert,
Niederländer)
- ...und Wissenschaftlern
verwendet



Digitale Bilder



- Bildverarbeitungsprozess:
 - (Loch-) Kameramodell
 - **Rasterisierung** zur Erzeugung eines digitalen Bildes





(Graustufen-) Bild

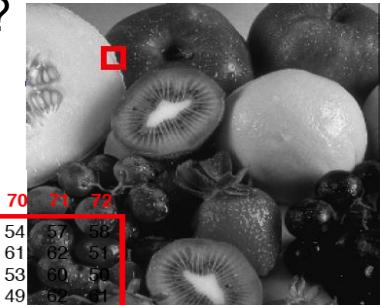
■ Ziele der Computer Vision

- Wie kann man Obst in einem Raster von (graustufen) Zahlen erkennen?
- Wie kann man Tiefen-informationen aus einem Raster von (graustufen) Zahlen herleiten?
- ...

■ computer vision = das Problem der „umgekehrten Grafik“?

■ Ziele der Computergrafik

- Wie kann man ein Raster von (graustufen) Zahlen erzeugen, das wie Obst aussieht?
- Wie kann man ein Raster von (graustufen) Zahlen erzeugen, sodass der menschliche Betrachter Tiefe wahrnimmt?
- ...



x =	58	59	60	61	62	63	64	65	66	67	68	69	70	71	72	
y =	41	210	209	204	202	197	247	143	71	64	80	84	54	54	57	58
42	206	196	203	197	195	210	207	56	63	58	53	53	53	61	62	51
43	201	207	192	201	198	213	156	69	65	57	55	52	53	60	59	50
44	216	206	211	193	202	207	208	57	69	60	55	77	49	56	51	41
45	221	206	211	194	196	197	220	56	63	60	55	46	97	58	106	111
46	209	214	224	199	194	193	204	173	64	60	59	51	62	56	48	49
47	204	212	213	208	191	190	191	214	60	62	66	76	51	49	55	55
48	214	215	215	207	208	180	172	188	69	72	55	49	56	52	56	56
49	209	205	214	205	204	196	187	196	86	62	66	87	57	60	48	48
50	208	209	205	203	202	186	174	185	149	71	63	55	55	45	56	56
51	207	210	211	199	217	194	183	177	209	90	62	64	52	93	52	52
52	208	205	209	209	197	194	183	187	187	239	58	68	61	51	56	56
53	204	206	203	209	195	203	188	185	183	221	75	61	58	60	60	60
54	200	203	199	236	188	197	183	190	183	196	122	63	58	64	66	66
55	205	210	202	203	199	197	196	181	173	186	105	62	57	64	63	63

Konfluenz



Konfluenz: wo Vision und Graphics zusammenfließen



Vor dem digitalen Zeitalter: Menschen und Kunst Wiedergewinnung von 3D-Strukturen in 2D



TECHNISCHE
UNIVERSITÄT
DARMSTADT



Menschen und Kunst

Wiedergewinnung von 3D-Strukturen



TECHNISCHE
UNIVERSITÄT
DARMSTADT



“Yves Saint Laurent – the film”

125 Jahre Eiffelturm

Fallstudie

Computer Vision und Objekterkennung

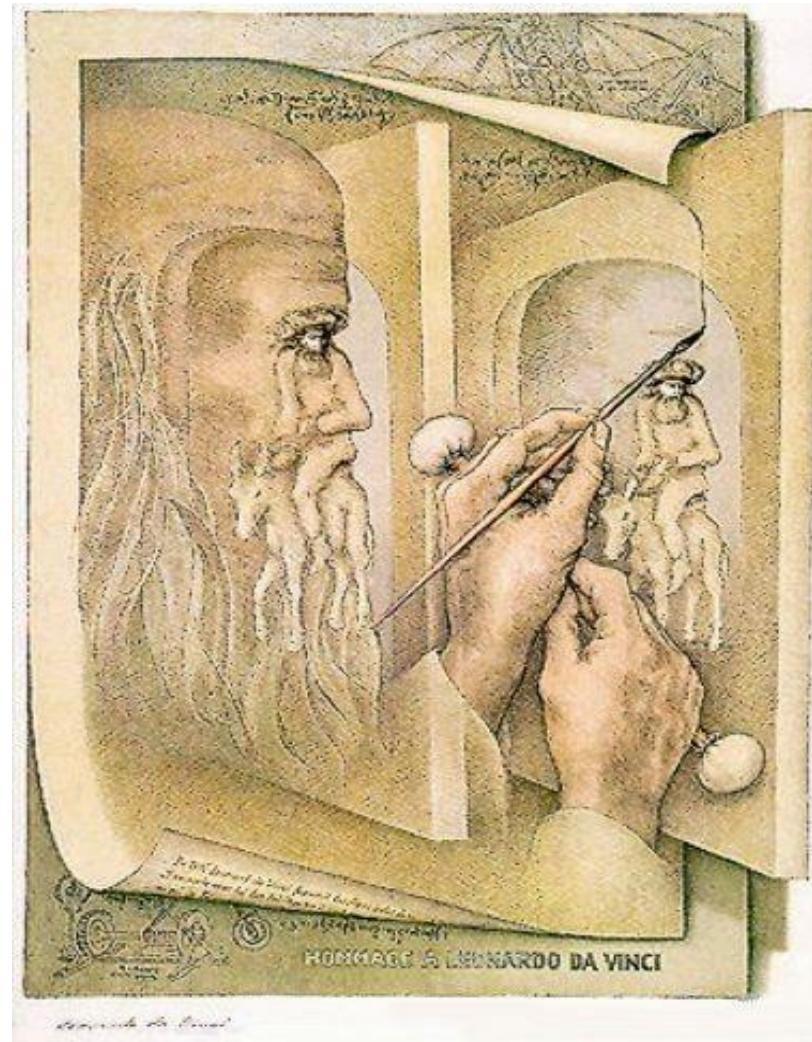


TECHNISCHE
UNIVERSITÄT
DARMSTADT

- Ist es mehr als umgekehrte Grafik?
- Wie erkennt man (als Mensch)
 - die Banane?
 - das Glas?
 - das Handtuch?
- Wie kann man Computer dazu bringen, dies ebenso zu tun?



Schwierigkeit des Erkennens



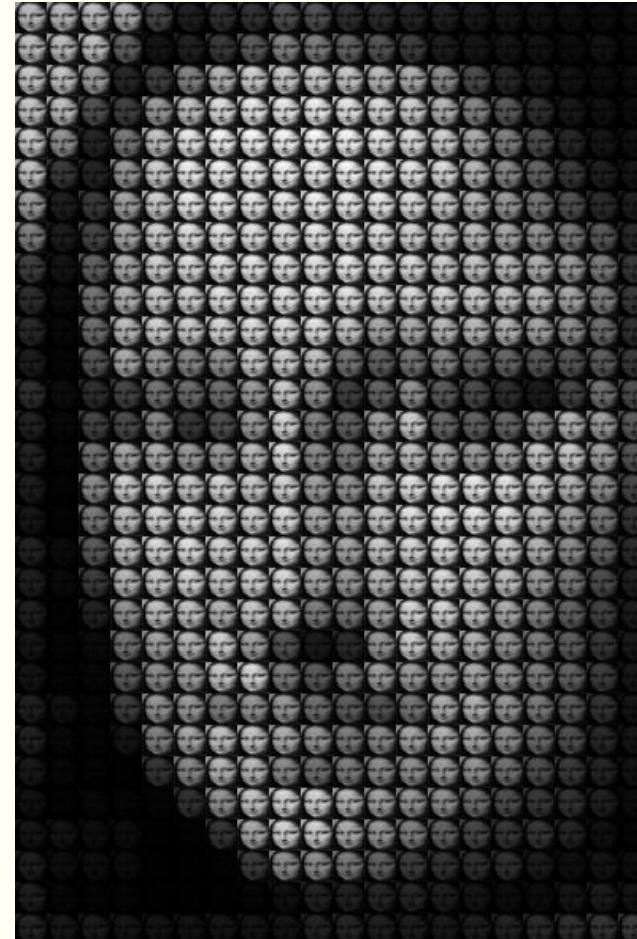
Schwierigkeit des Erkennens



Schwierigkeit des Erkennens



TECHNISCHE
UNIVERSITÄT
DARMSTADT



Frau in einem gelben Bikini

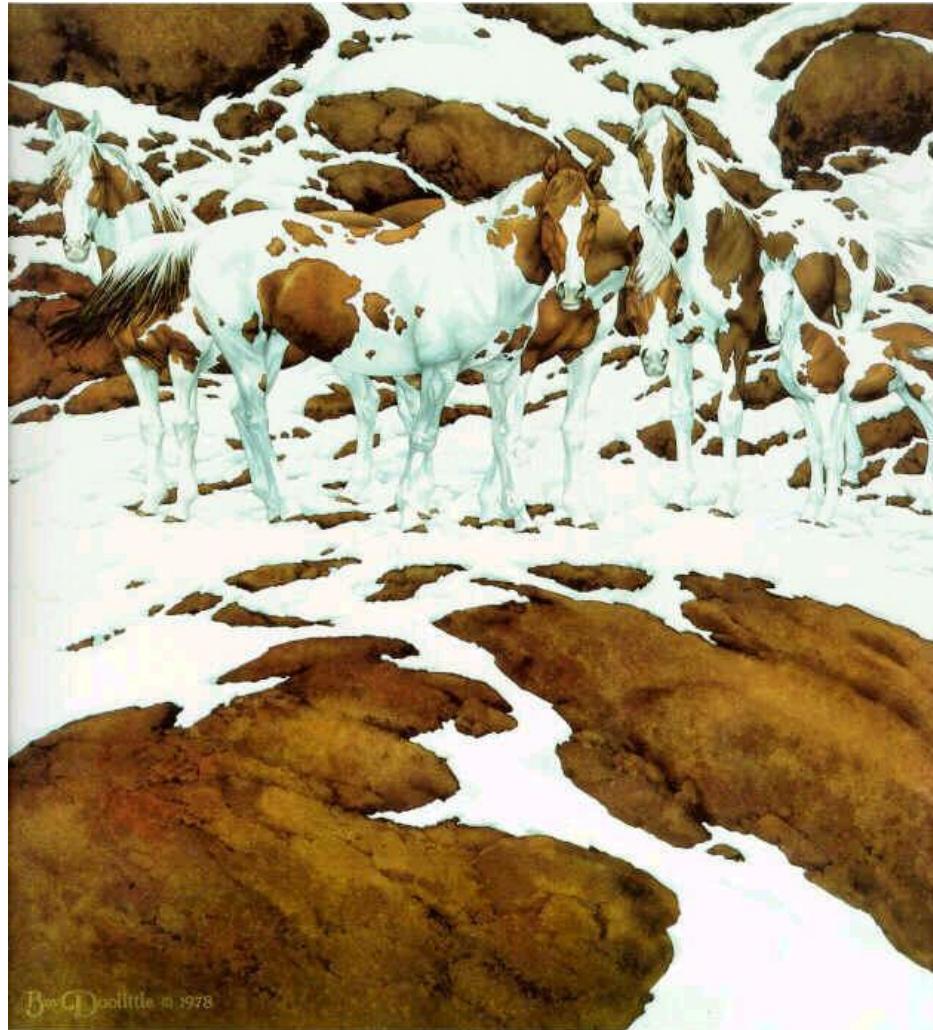


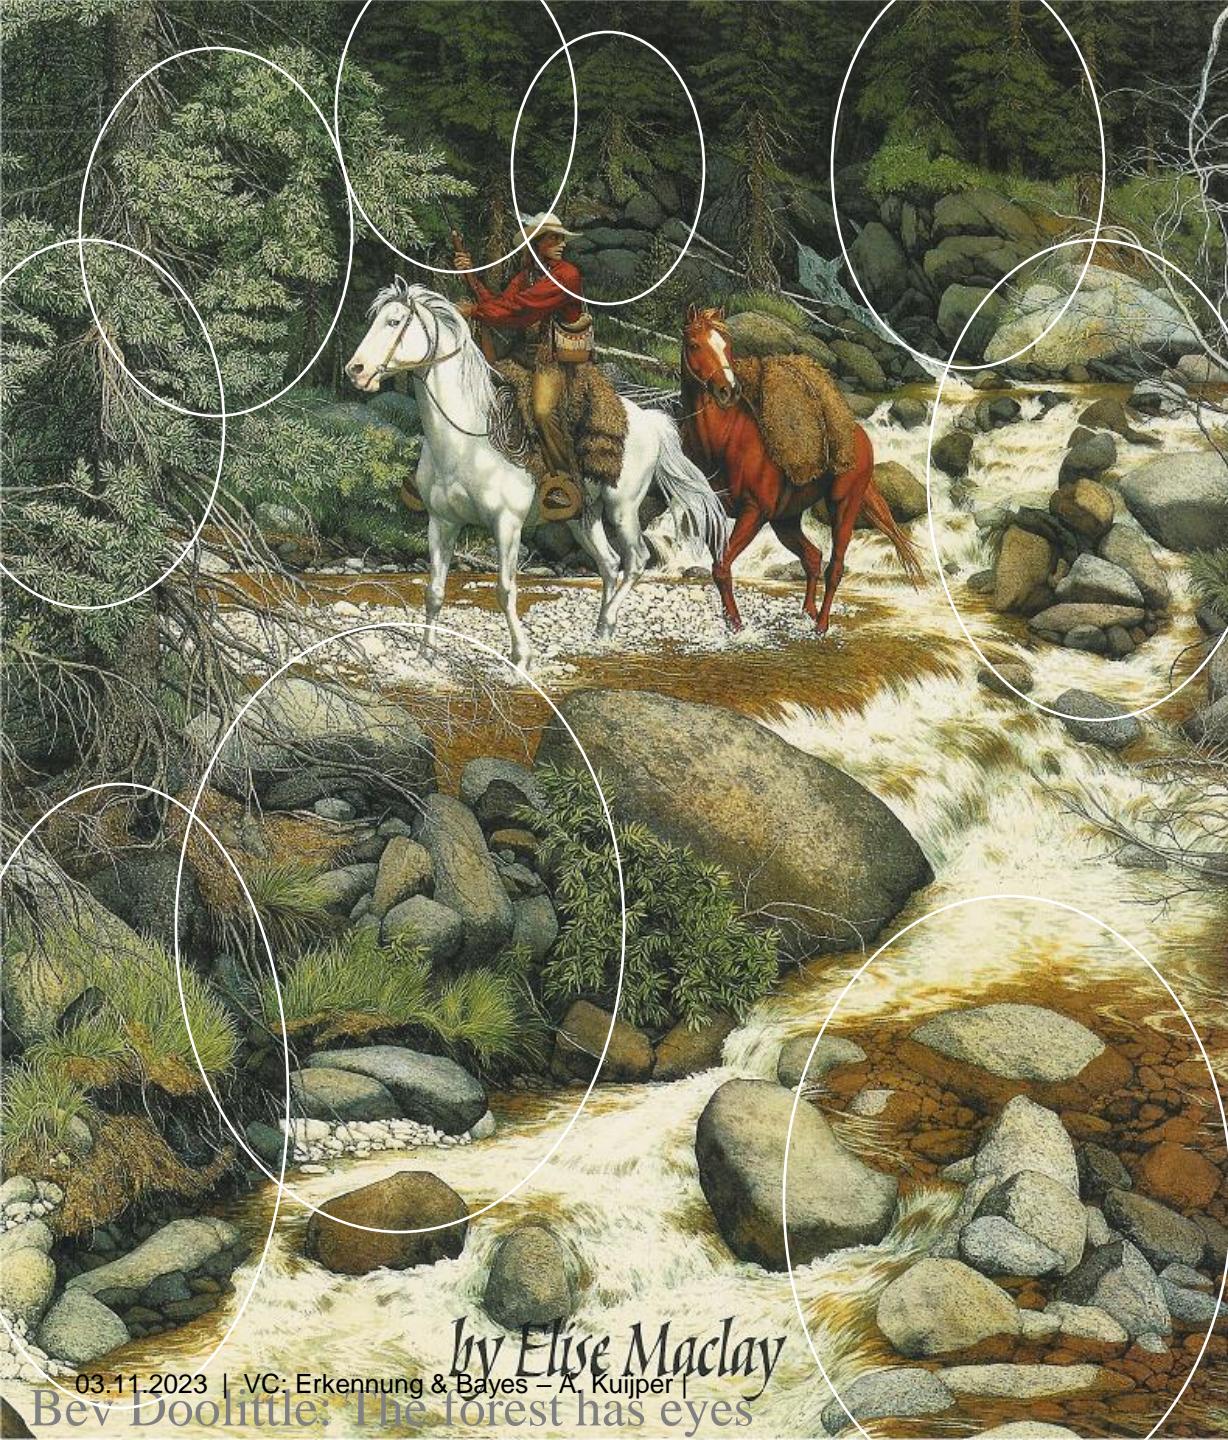
TECHNISCHE
UNIVERSITÄT
DARMSTADT



- David Mach: <http://www.dailyrecord.co.uk/news/scottish-news/2012/04/21/stunning-works-by-scots-artist-set-to-go-under-the-hammer-86908-23831695/>

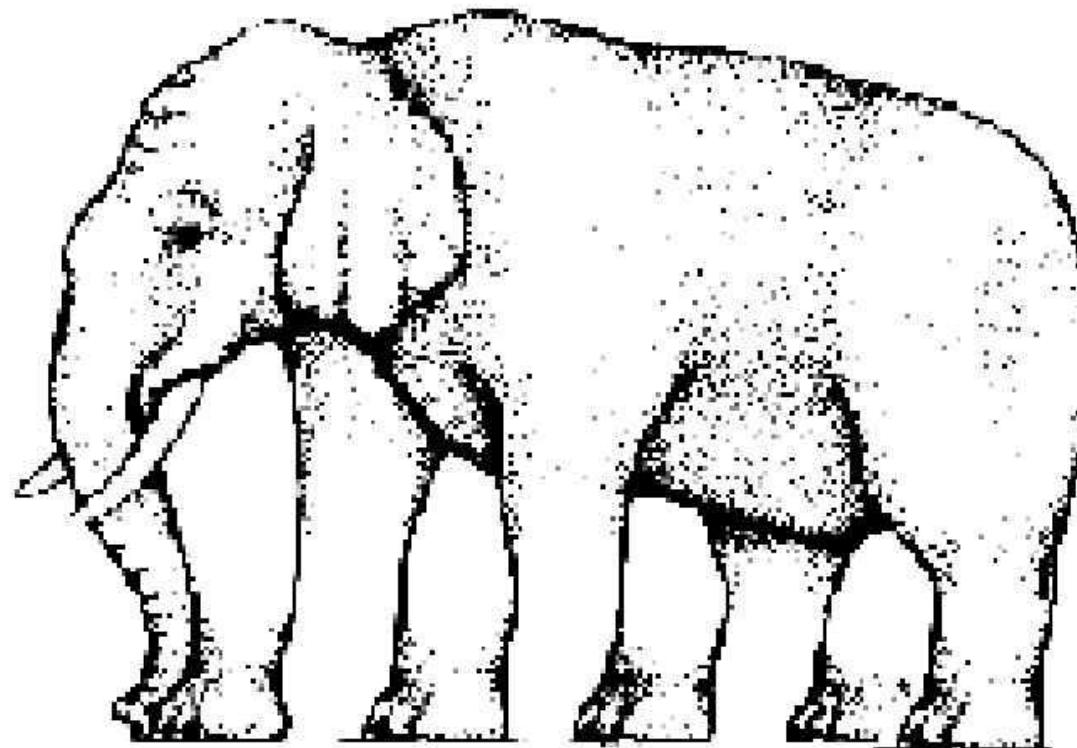
Schwierigkeit des Erkennens



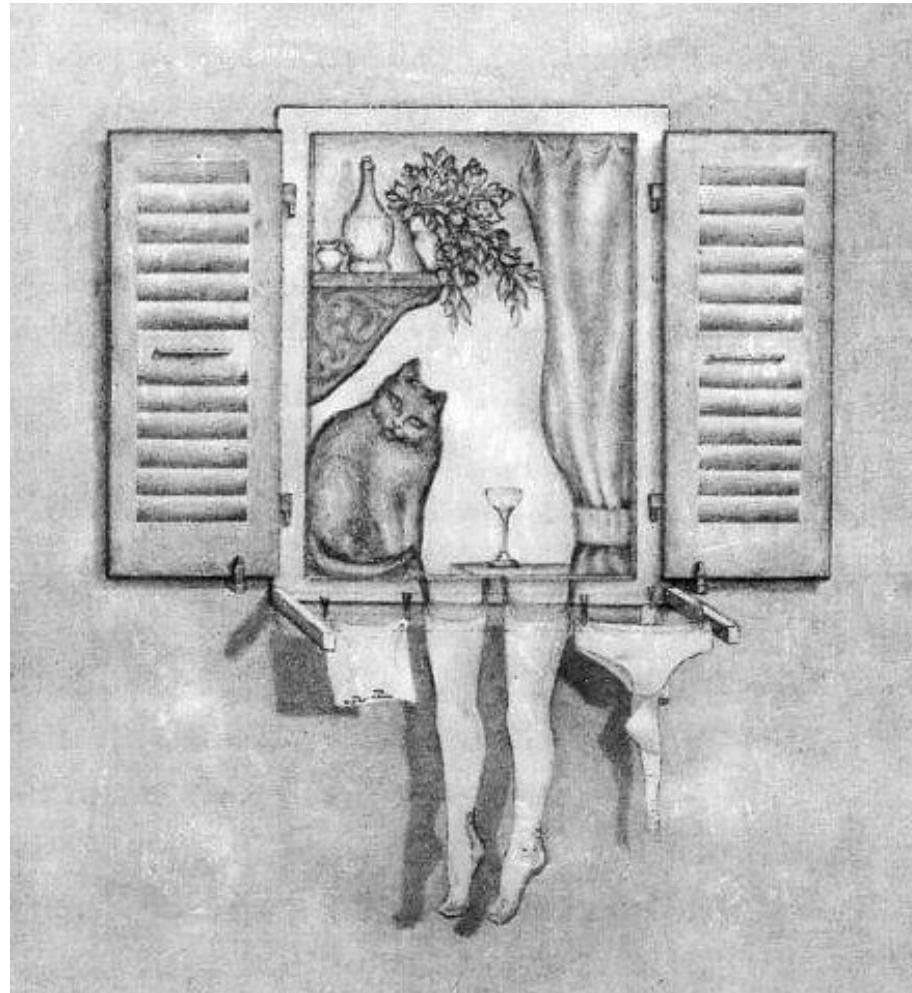


TECHNISCHE
UNIVERSITÄT
DARMSTADT

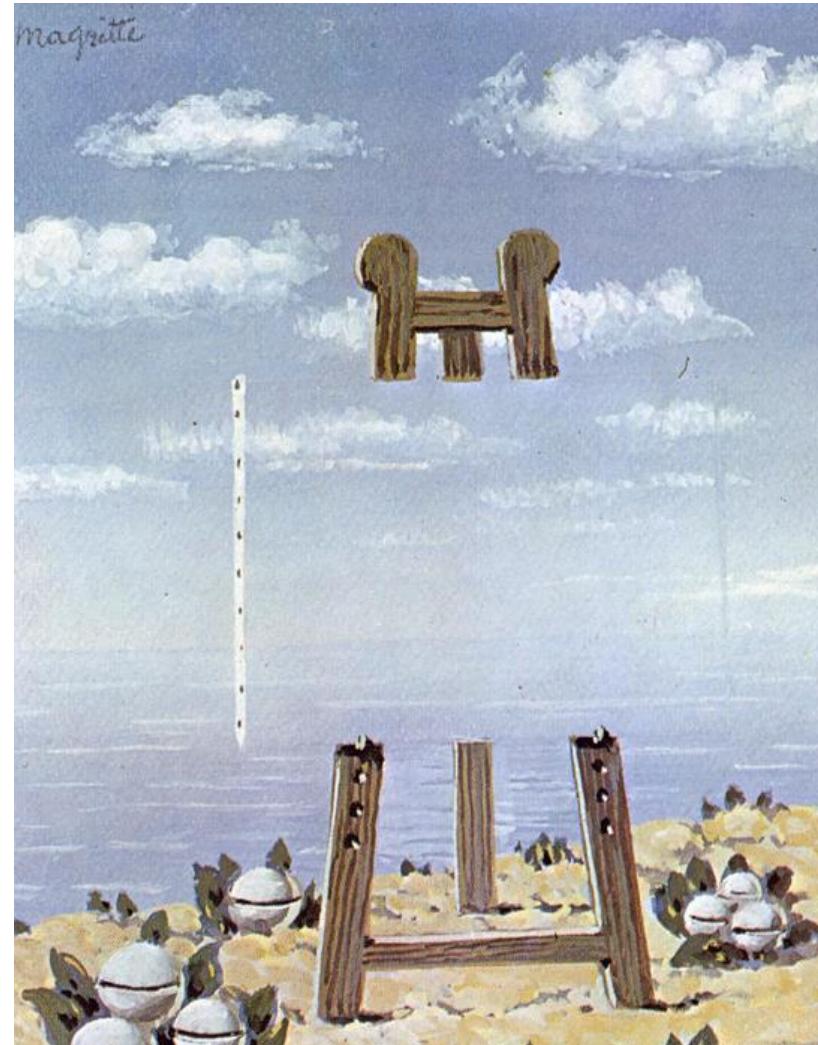
Schwierigkeit des Erkennens



Schwierigkeit des Erkennens



Schwierigkeit des Erkennens



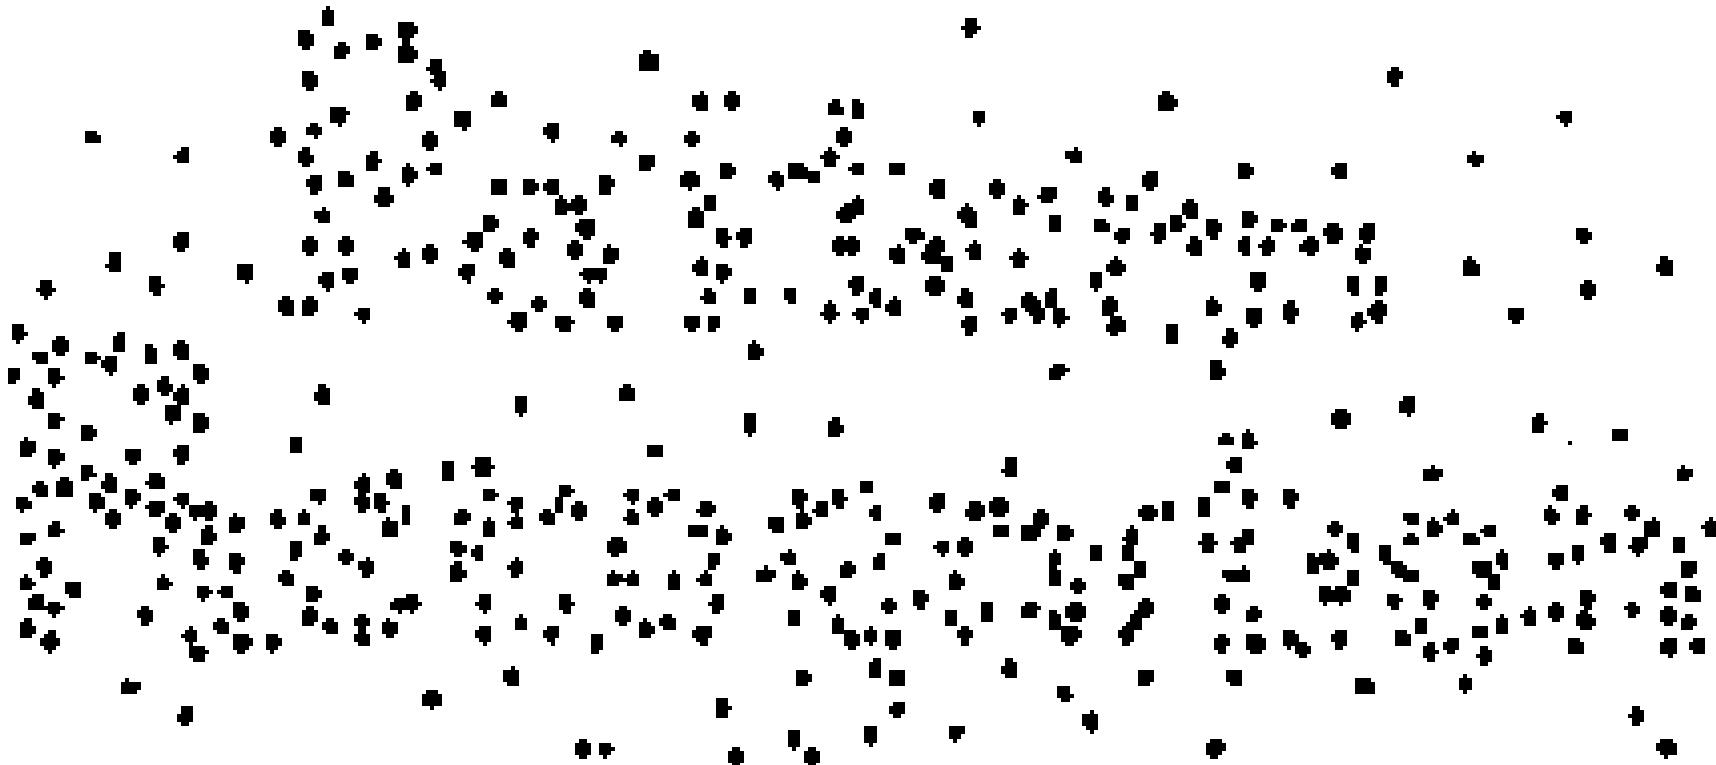
Erkennung: Die Rolle des Zusammenhangs

- Antonio Torralba





Erkennung: Die Rolle des Zusammenhangs

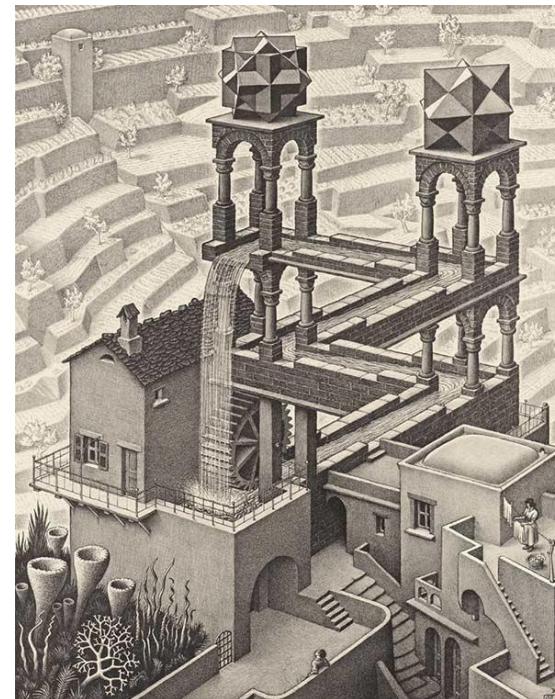


Fehler im Zusammenhang



TECHNISCHE
UNIVERSITÄT
DARMSTADT

- <http://www.mcescher.com/gallery/impossible-constructions/>





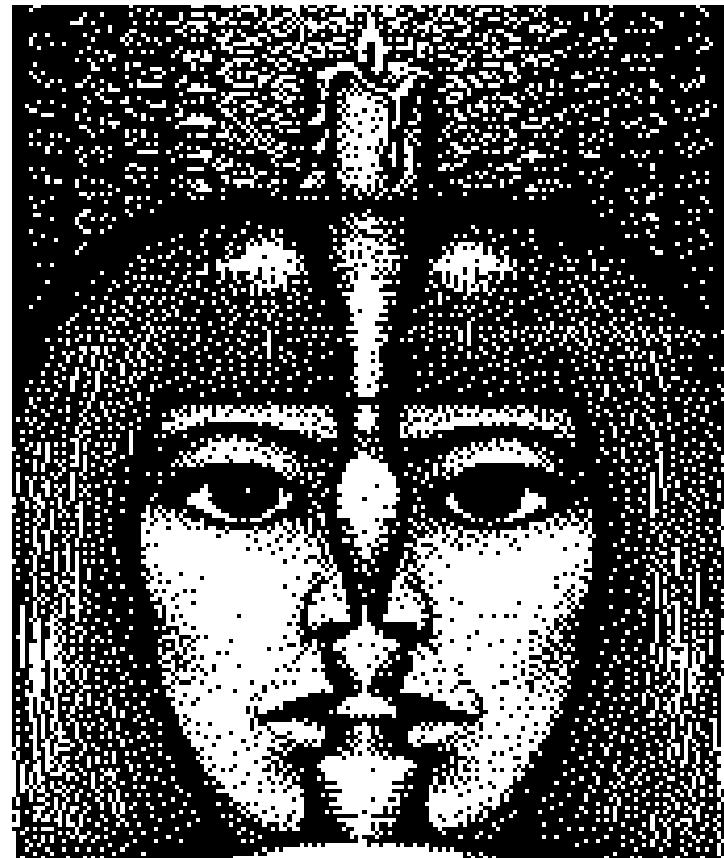
Objekterkennung - Intuitionen...

- Wichtige Komponenten der Beschreibung
 - lokale Beschreibung / Merkmale
 - z.B. Augen, Mund, Nase
 - globale Anordnung der lokalen Merkmale
 - z.B. relative Positionen, relative Grösse
- Aber auch:
 - schnelle Generierung von guten Hypothesen
 - Segmentierung der Bildbereiche
 - Szenenkontext
 - ...



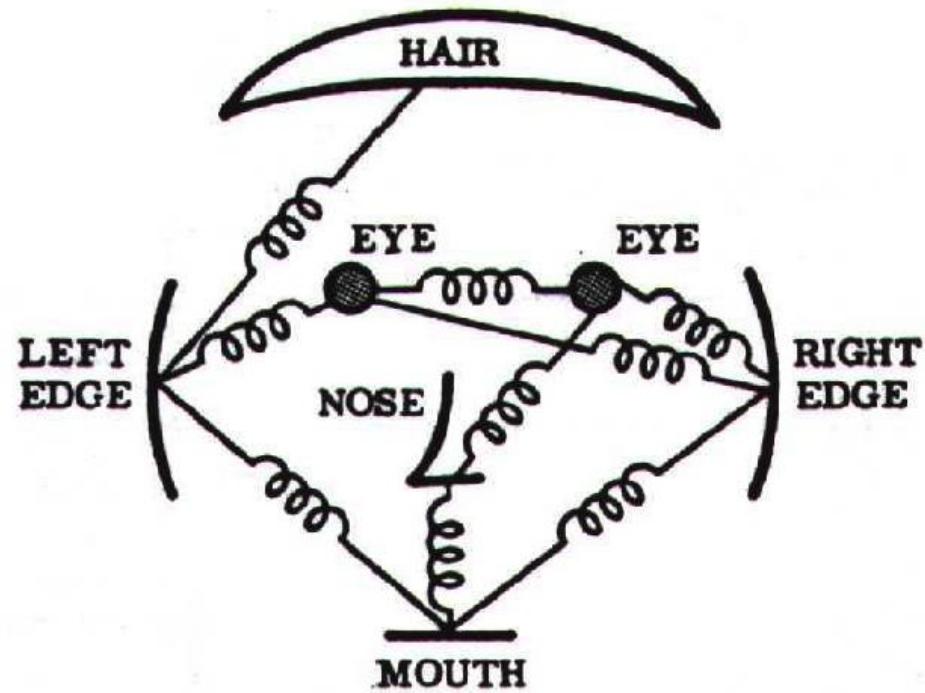
TECHNISCHE
UNIVERSITÄT
DARMSTADT

Ein oder zwei Gesichter?



Bildaufbau (Pictorial Structure)

- Fischler und Elschlager 1973
- Das Modell hat zwei Komponenten:
 - Teile (parts)
(2D Bildfragmente)
 - Aufbau (structure)
(Anordnung der Teile)



Deformationen



A



B



C



D

Durcheinander (Clutter)





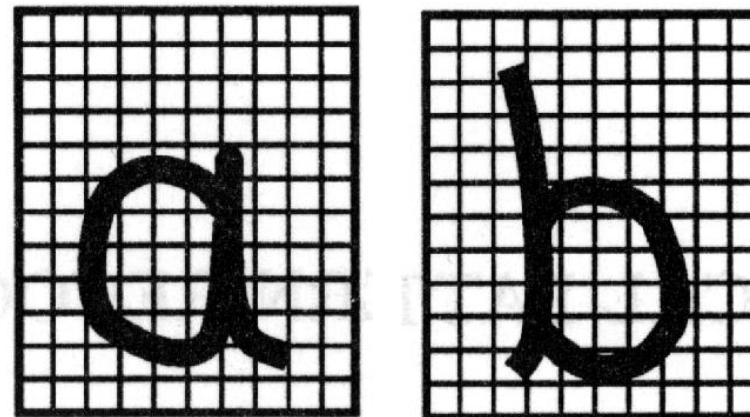
Überblick

- Computer Vision
 - Objekterkennung und Objektdetektion als Fallbeispiel
 - Motivation heutiger Ansätze
- **Bayes Decision Theory**
 - **Verwendung von Merkmalen zur Objekterkennung**
 - **Naive Bayes Klassifikator**
- Gesichtsdetektion
 - Schneiderman & Kanade: Naive Bayes Klassifikator
de facto einer der erfolgreichsten Verfahren
- Diskussion und Ausblick

Bayes Decision Theory



- Beispiel: Buchstabenerkennung



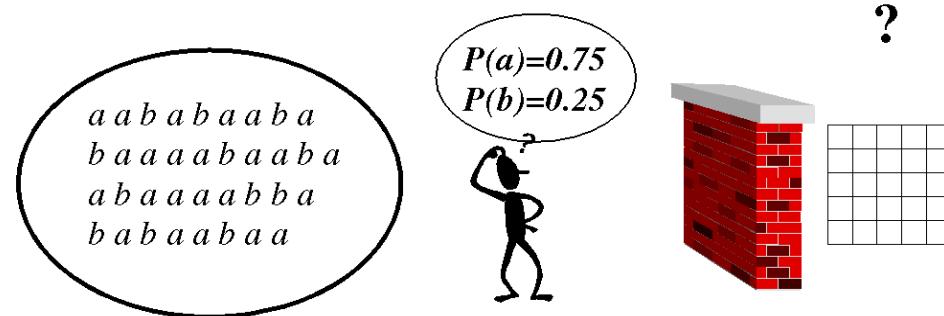
- Ziel: klassifiziere neuen Buchstaben, so dass die Wahrscheinlichkeit der Fehlklassifikation minimiert wird
- 3 Konzepte:
 - a priori Wahrscheinlichkeit (Anfangswahrscheinlichkeit, prior probability)
 - bedingte Wahrscheinlichkeit (Conditional probability)
 - a posteriori Wahrscheinlichkeit (posterior probability)

Bayes Decision Theory

1. Konzept: **Priors** (a priori Wahrscheinlichkeit)

$$P(C_k)$$

- ## ■ Beispiel:



$$C_1 = a \quad P(C_1) = 0.75$$

$$C_2 = b \quad P(C_2) = 0.25$$

- #### ▪ Generell:

$$\sum_k P(C_k) = 1$$

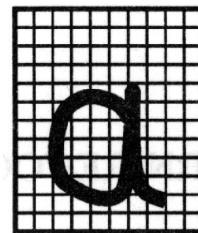
Bayes Decision Theory



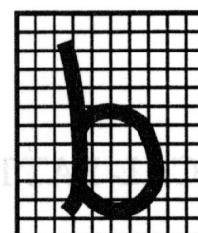
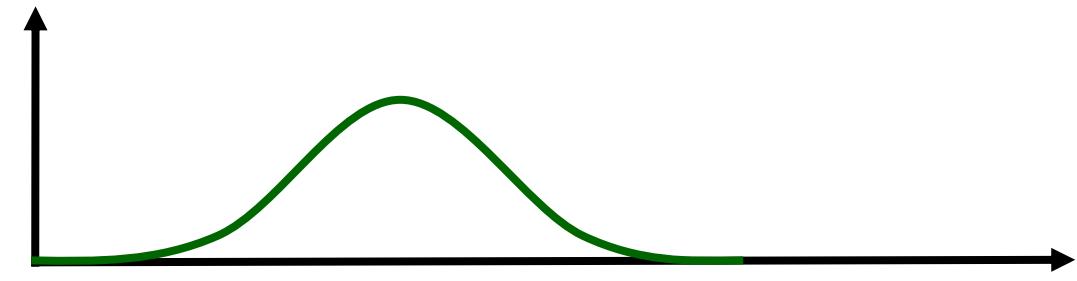
2. Konzept: bedingte Wahrscheinlichkeit

- mit 'x' Merkmalsvektor (feature)
- 'x' misst/beschreibt Eigenschaft(en)
 - Beispiel: # der schwarzen Pixel, Höhen-Breiten-Verhältnis...

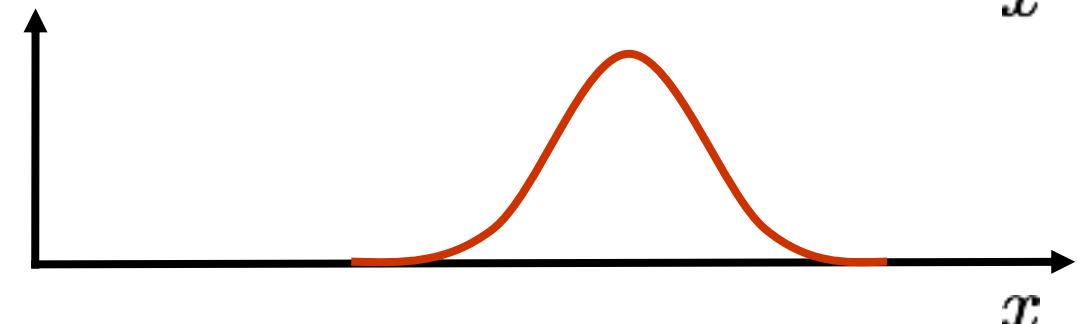
$$P(x|C_k)$$



$$p(x|a)$$



$$p(x|b)$$





Bemerkung bzgl. ‘pdf’ vs. Probability...

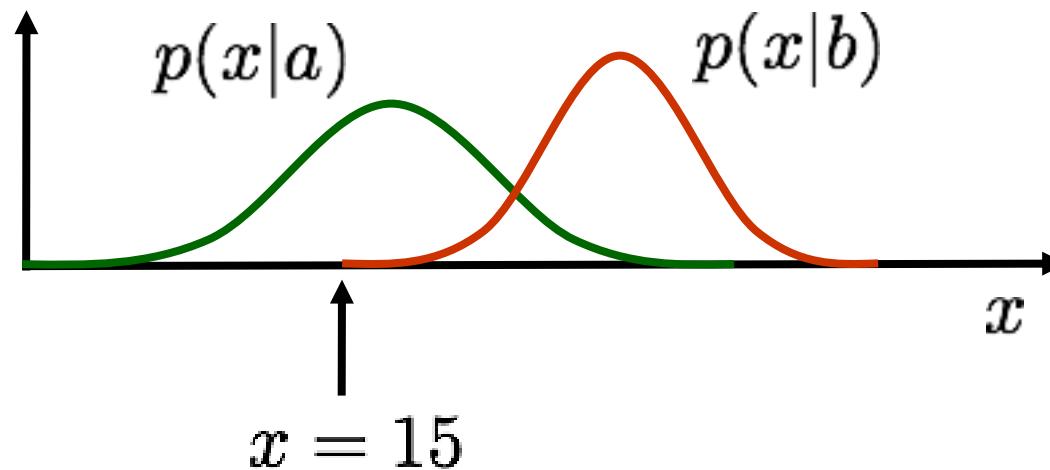
- Zusammenhang zwischen Wahrscheinlichkeitsdichte und Wahrscheinlichkeit für
 - Wahrscheinlichkeit, daß x ist in dem Intervall (x_0, x_1) , ist definiert durch:
$$Pr(x_0 < x < x_1) = \int_{x_0}^{x_1} p(t)dt$$
- Wahrscheinlichkeit $P(x)$ ist somit nicht direkt definiert
- Im folgenden verwenden wir $P(x)$ in der folgenden Weise:
 - wenn dx unendlich klein wird, kann die Wahrscheinlichkeit, dass x ist in dem Intervall $(x, x+dx)$ ist, wie folgt berechnet werden:

$$P(x) = Pr(x < t < x + dx) = p(x)dx$$

(Riemann....)

Bayes Decision Theory

- Beispiel:

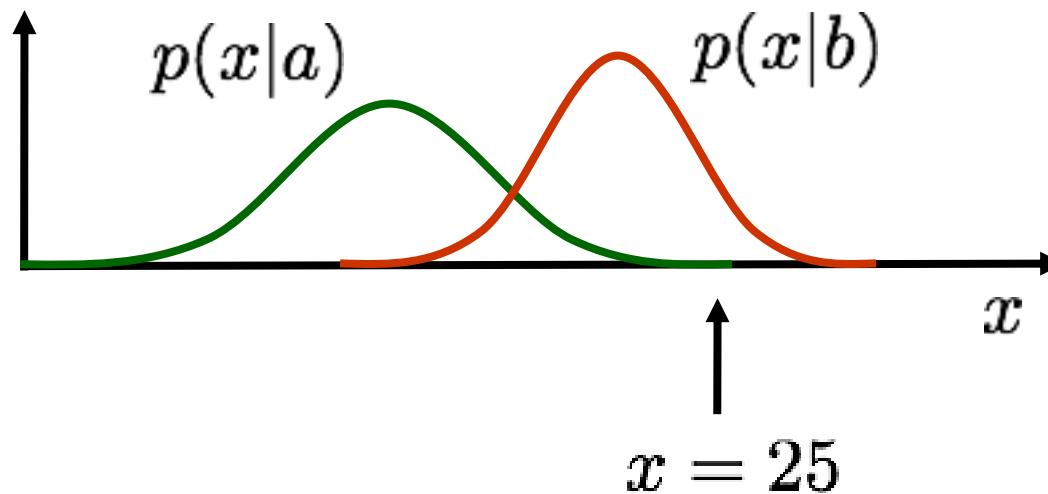


- Frage:

- welche Klasse?
- die Entscheidung sollte hier ‘a’ sein da $p(15|b) == 0$

Bayes Decision Theory

- Beispiel:

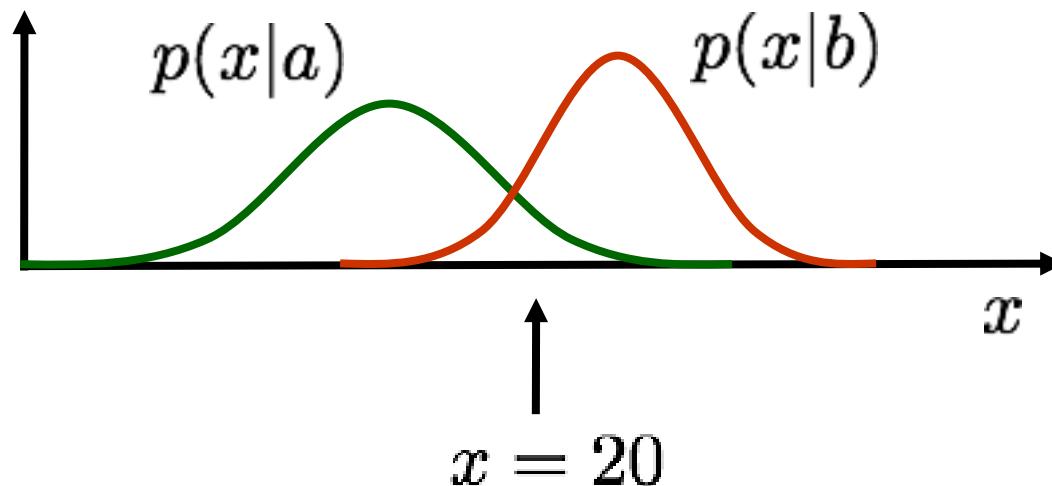


- Frage:

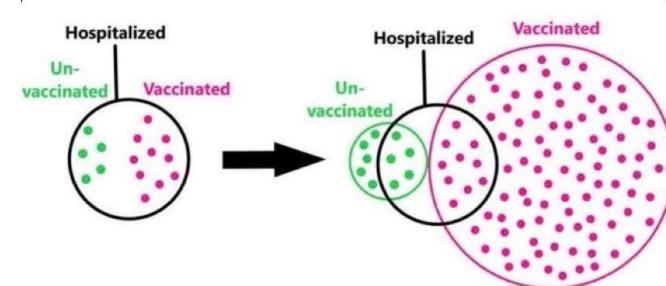
- welche Klasse?
- da $p(25|a) == 0$, sollte die Entscheidung hier ‘b’ sein

Bayes Decision Theory

- Beispiel:



- Frage:
 - welche Klasse?
 - $p(20|a) < p(20|b)$, aber
 - $P(a) = 0.75$ und $P(b) = 0.25...$
 - $p(x|a) P(a) > p(x|b) P(b)$
 - das heisst, die Entscheidung ist hier ‘a’ !!





Bayes Decision Theory

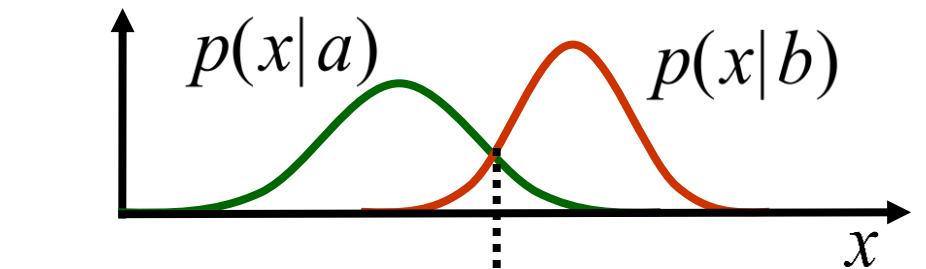
3. Konzept: a posteriori Wahrscheinlichkeit (**posterior**)

- **Wahrscheinlichkeit** der Klasse C_k ,
gegeben ein bestimmter Merkmalsvektor ‘x’
- Bayes’ Theorem:

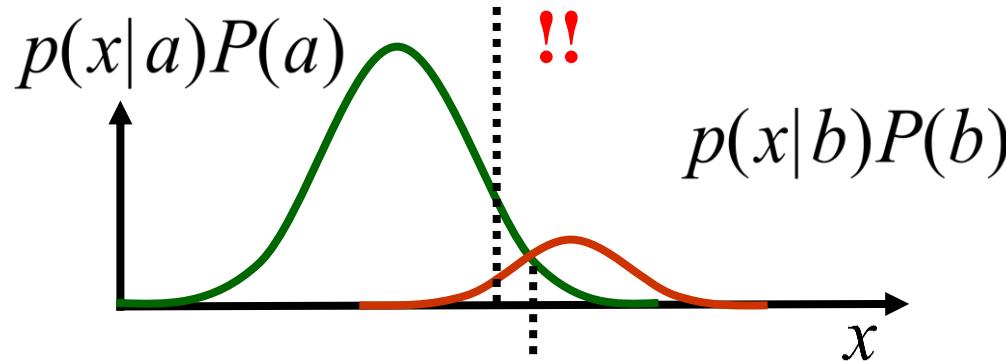
$$P(C_k|x) = \frac{P(x|C_k)P(C_k)}{P(x)} = \frac{P(x|C_k)P(C_k)}{\sum_j P(x|C_j)P(C_j)}$$

$$\textit{Posterior} = \frac{\textit{Likelihood} \times \textit{Prior}}{\textit{Normalization Factor}}$$

Bayes Decision Theory

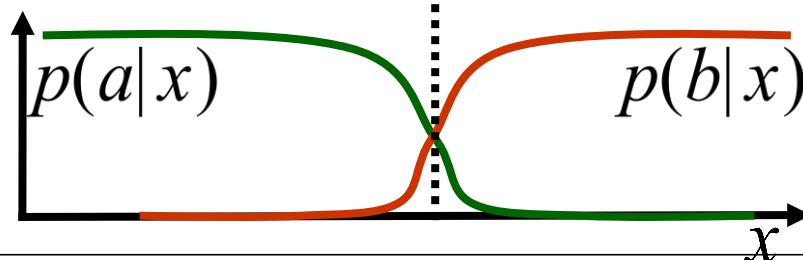


Likelihood



Likelihood \times Prior

Entscheidungsgrenze



$$\text{Posterior} = \frac{\text{Likelihood} \times \text{Prior}}{\text{Normalization factor}}$$

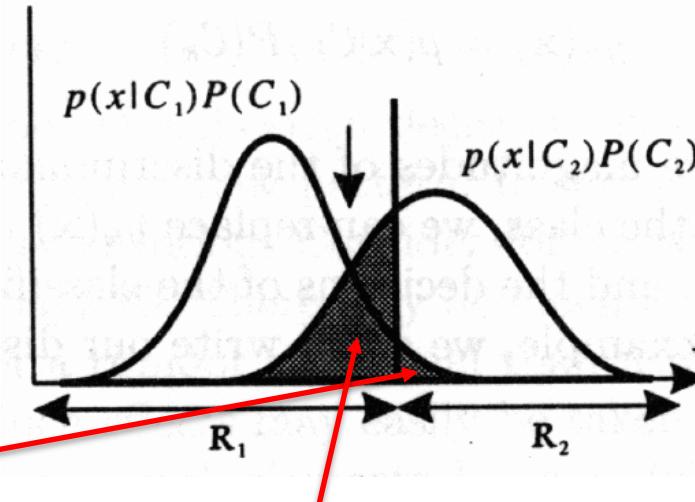
Bayes Decision Theory

- Ziel:

Wahrscheinlichkeit der Fehlklassifikation minimieren

Oder:

Entscheidungsgrenze zwischen R_1 und R_2 bestimmen



$$\begin{aligned}
 P(error) &= P(x \in R_2, C_1) + P(x \in R_1, C_2) \\
 &= P(x \in R_2 | C_1)P(C_1) + P(x \in R_1 | C_2)P(C_2) \\
 &= \int_{R_2} p(x \in R_2 | C_1)P(C_1)dx + \int_{R_1} p(x \in R_1 | C_2)P(C_2)dx
 \end{aligned}$$

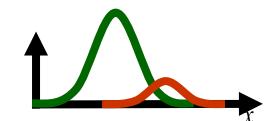
Bayes Decision Theory

- Entscheidungsregel:
 - entscheide C_1 wenn

$$P(C_1|x) > P(C_2|x)$$

- das ist äquivalent zu:

$$P(x|C_1)P(C_1) > P(x|C_2)P(C_2)$$



- das ist äquivalent zu (genannt Likelihood Ratio Test):

$$\frac{P(x|C_1)}{P(x|C_2)} > \frac{P(C_2)}{P(C_1)} = \lambda$$



Bayes Decision Theory



- Verallgemeinerung zu mehr als 2 Klassen:
 - entscheide Klasse ‘k’ immer dann, wenn diese die grösste a posteriori Wahrscheinlichkeit hat:

$$P(C_k|x) > P(C_j|x) \text{ for all } j \neq k$$

- oder äquivalent:

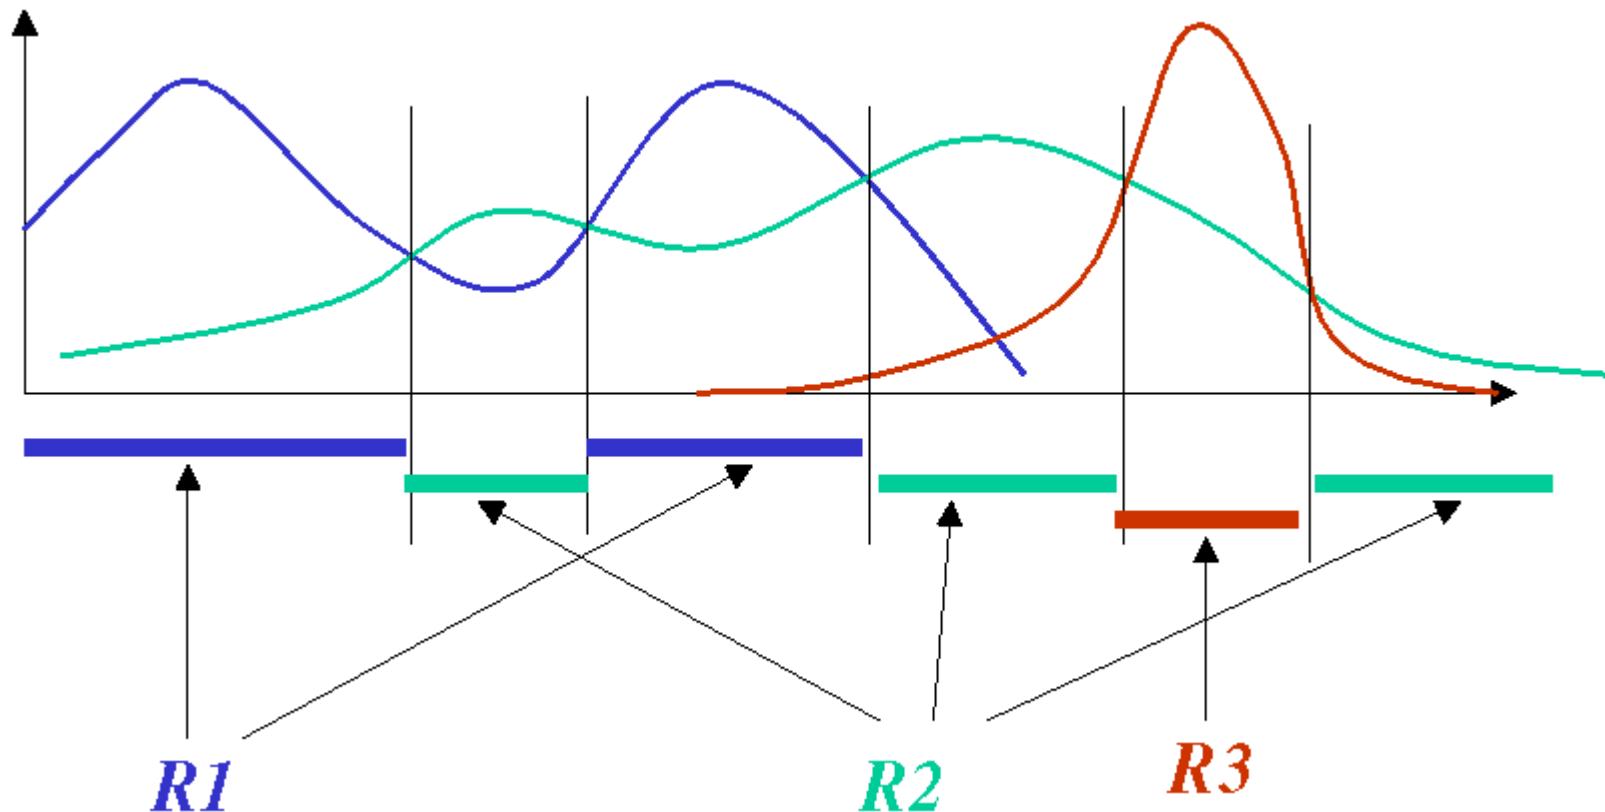
$$P(x|C_k)P(C_k) > P(x|C_j)P(C_j) \text{ for all } j \neq k$$

$$\frac{P(x|C_k)}{P(x|C_j)} > \frac{P(C_j)}{P(C_k)} \text{ for all } j \neq k$$

Bayes Decision Theory

- Entscheidungsregionen:

$$R_1, R_2, \dots$$





Bayes Decision Theory

- Verwendung von zwei Merkmalen: x_1, x_2
 - z.B. Höhe & Breite, Länge & Gewicht, Farbe & Preis, ...

$$P(C_k|x_1, x_2) = \frac{P(x_1, x_2|C_k)P(C_k)}{P(x_1, x_2)}$$

- Problematisch: Schätzung der 2-dimensionalen Wahrscheinlichkeitsdichten nicht immer möglich
 - davon haben wir zwei:

$$P(x_1, x_2|C_k)$$

$$P(x_1, x_2)$$



Naive Bayes Classifier

- Annahme des naive Bayes Klassifikators:
 - Die beiden Merkmale x_1, x_2 sind (statistisch) *unabhängig*
 - Damit wird:

$$P(x_1, x_2 | C_k) = P(x_1 | C_k)P(x_2 | C_k)$$

$$P(x_1, x_2) = P(x_1)P(x_2)$$

- Naive Bayes Klassifikator (für 2 Merkmale)

$$P(C_k | x_1, x_2) = \frac{P(x_1 | C_k)}{P(x_1)} \frac{P(x_2 | C_k)}{P(x_2)} P(C_k)$$



Naive Bayes Classifier

- Verwendung von d Merkmalen: x_1, x_2, \dots, x_d

$$P(C_k|x_1, \dots, x_d) = \frac{P(x_1, \dots, x_d|C_k)P(C_k)}{P(x_1, \dots, x_d)}$$

- Naive Bayes Klassifikator:

- Annahme, dass alle Merkmale x_i statistisch *unabhängig* sind.

$$P(C_k|x_1, \dots, x_d) = \prod_{i=1}^d \frac{P(x_i|C_k)}{P(x_i)} P(C_k)$$

- Die Annahme der Unabhängigkeit ist **oft nicht richtig**, ergibt aber häufig gute Ergebnisse und ist somit ein guter Vergleich bzw. Basis zum Vergleich.



Naive Bayes Classifier

$$P(C_k|x_1, \dots, x_d) = \prod_{i=1}^d \frac{P(x_i|C_k)}{P(x_i)} P(C_k)$$

- Spezialfall 2-Klassenproblem:

- Entscheide Klasse C_1 wenn:

$$P(C_1|x_1, \dots, x_d) > P(C_2|x_1, \dots, x_d)$$

$$\prod_{i=1}^d \frac{P(x_i|C_1)}{P(x_i)} P(C_1) > \prod_{i=1}^d \frac{P(x_i|C_2)}{P(x_i)} P(C_2)$$

- vereinfacht zum “Likelihood Ratio Test”:

$$\prod_{i=1}^d \frac{P(x_i|C_1)}{P(x_i|C_2)} > \frac{P(C_2)}{P(C_1)} = \lambda$$



Probability Density Estimation

- Wrap-up:
 - Bayes optimale Klassifikation
 - Verwendung der Wahrscheinlichkeiten:

$$P(x|C_k)P(C_k)$$

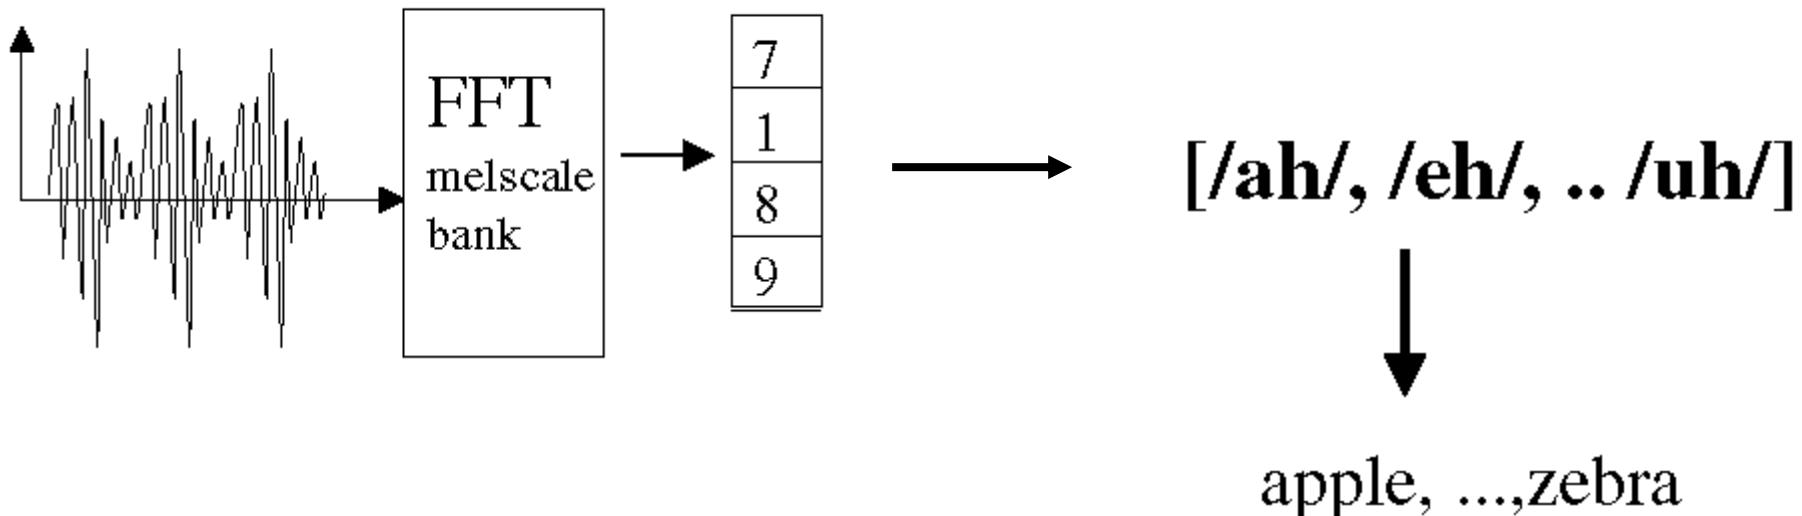


- Schätzung der Wahrscheinlichkeitsdichten (density estimation):
 - Schätzung der Wahrscheinlichkeitsdichte einer Klasse C_k

$$p(x|C_k)$$

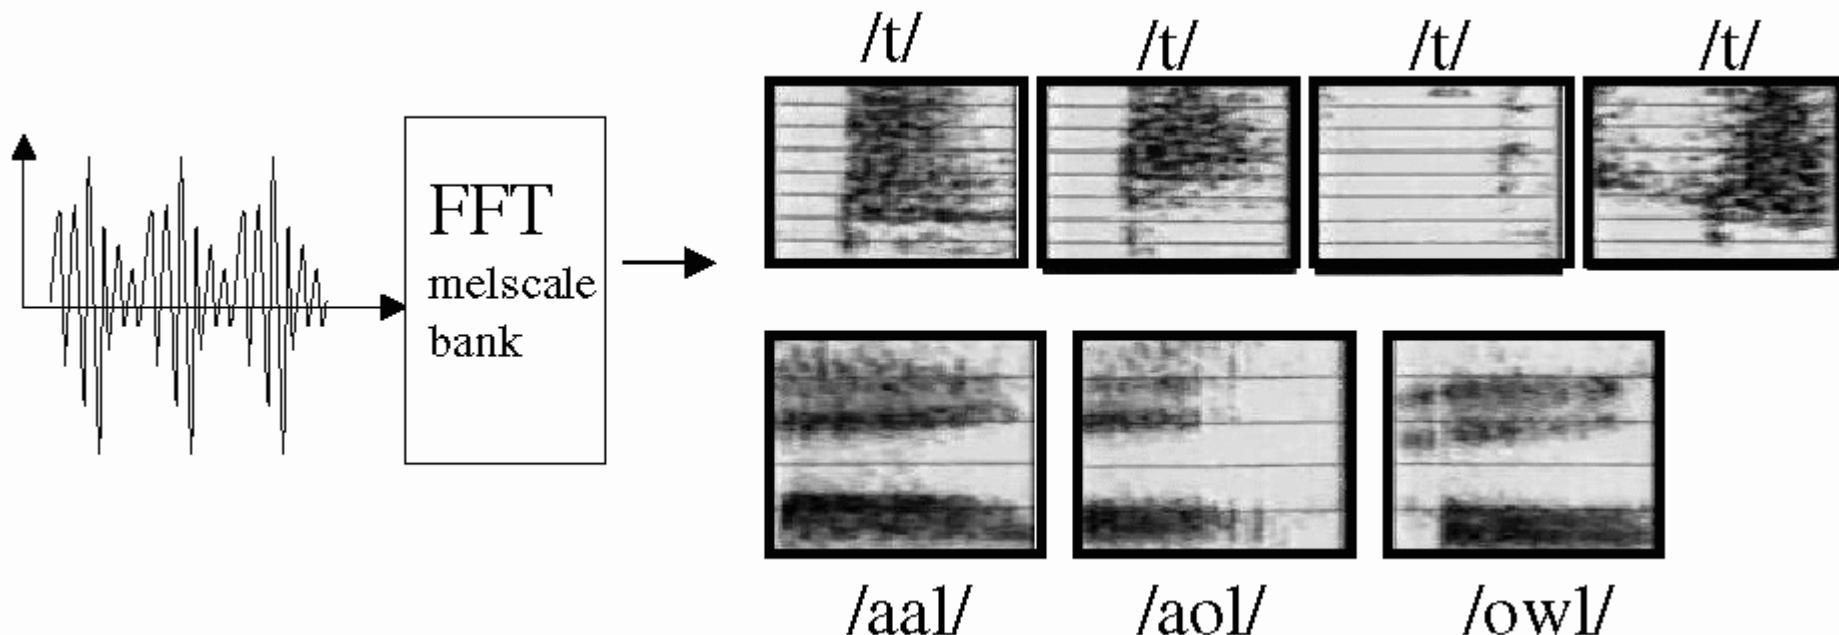
Bayes Decision Theory

- Was ist an $P(x|C_k)P(C_k)$ so interessant?
 - Beispiel #1: Spracherkennung:



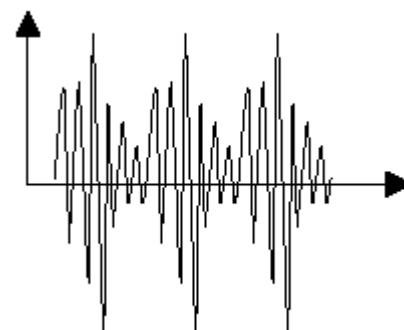
Bayes Decision Theory

- Was ist an $P(x|C_k)P(C_k)$ so interessant?
 - Beispiel #1: Spracherkennung:



Bayes Decision Theory

- Was ist an $P(x|C_k)P(C_k)$ so interessant?
 - Beispiel #1: Spracherkennung:



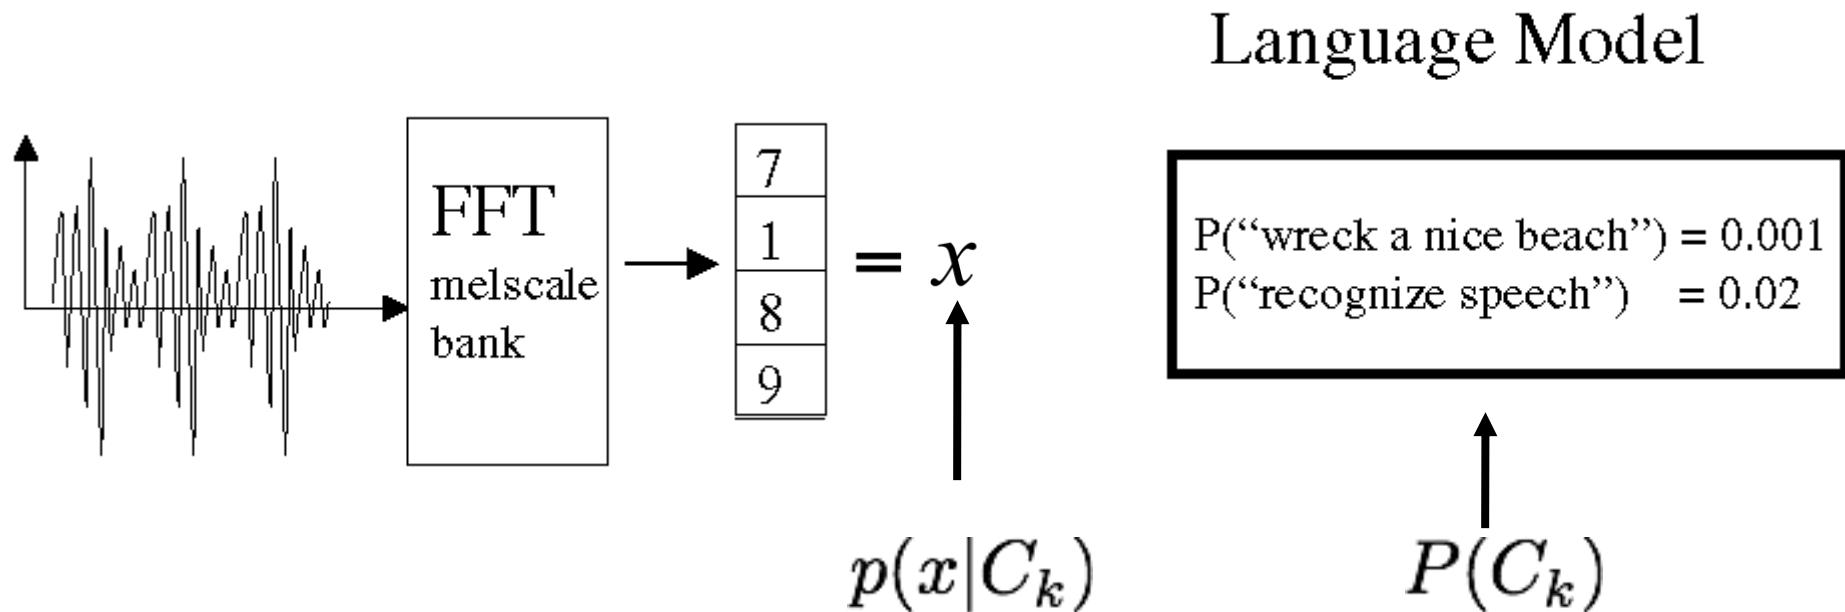
“This machine can recognize speech”

“This machine can wreck a nice beach”

- ▶ wie können wir den richtigen Satz erkennen ??

Bayes Decision Theory

- Was ist an $P(x|C_k)P(C_k)$ so interessant?
 - Beispiel #1: Spracherkennung:



Bayes Decision Theory

- Was ist an $P(x|C_k)P(C_k)$ so interessant?
 - Beispiel #2: Bildverarbeitung:

Low-Level
Image
Measurements

High-Level
Model
Knowledge

$$p(x | C_k)$$

$$P(C_k)$$



Überblick

- Computer Vision
 - Objekterkennung und Objektdetektion als Fallbeispiel
 - Motivation heutiger Ansätze
- Bayes Decision Theory
 - Verwendung von Merkmalen zur Objekterkennung
 - Naive Bayes Klassifikator
- Gesichtsdetektion
 - **Schneiderman & Kanade: Naive Bayes Klassifikator de facto einer der erfolgreichsten Verfahren**
- Diskussion und Ausblick



Appearance-Based Methods

Prinzip:

- Erscheinungsmodell (appearance model) aus (üblicherweise) großen Sammlungen von Bildern lernen
- Am häufigsten: Sliding Window Ansatz (d.h. über alle Positionen und Skalierungen!)
- Jedes Fenster (d.h. Teilbereich des Bildes) als „Gesicht“ oder „kein Gesicht“ klassifizieren

3 Aspekte:

1. Repräsentation des Objektes
 - lokale Merkmale (z.B. Auge, Mund, Nase, ...)
 - globale Anordnung der Merkmale
2. Trainingsdaten
 - sowohl positive Beispiele (z.B. Gesichter)
 - als auch negative Beispiele (z.B. keine Gesichter)
3. Klassifikator und Lernmethode

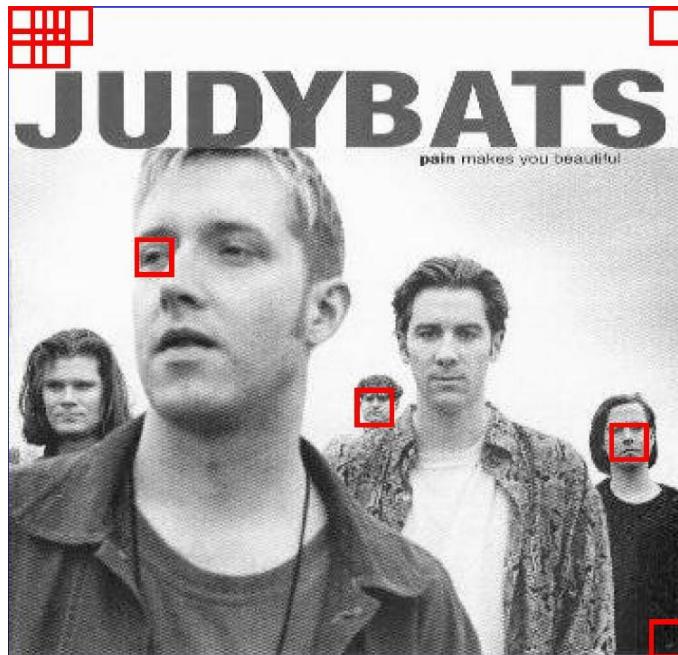
Appearance-Based Methods

Suchstrategie

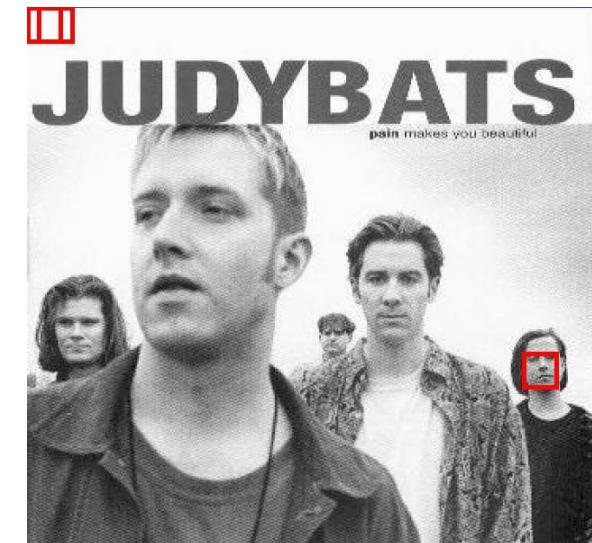


TECHNISCHE
UNIVERSITÄT
DARMSTADT

- Suchen über Raum und Skalierung (Sliding Window Approach)



• • •



Ein Eingabebild wird in Ein-Pixel-Schritten horizontal und vertikal gescannt

Das Bild wird um den Faktor 1,2 verkleinert, die Suche wiederholt

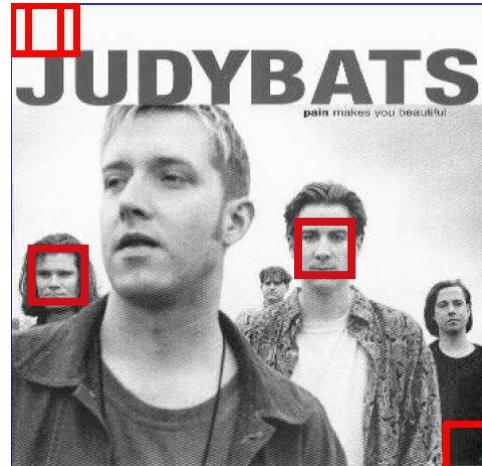
Appearance-Based Methods

Suchstrategie

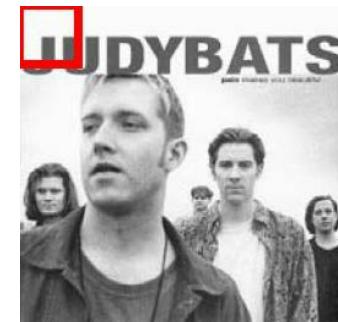


TECHNISCHE
UNIVERSITÄT
DARMSTADT

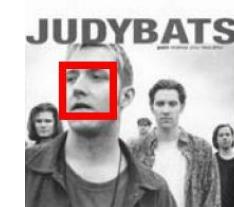
- Suchen über Raum und Skalierung (Sliding Window Approach)



• • •



• • •



Das Bild wird immer weiter um 1,2 verkleinert und es wird immer weiter gesucht, bis das Bild zu klein ist

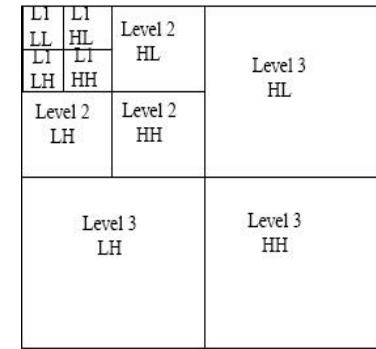


Beispiel: Gesichtsdetektion

- Schneiderman & Kanade - 1998
 - einer der performantesten Gesichtdetektoren

1. Aspekt: Repräsentation des Objektes

- Verwendung der Waveletzerlegung von Bildern:
Darstellung der Gesichtsmerkmale mit Frequenzen und deren Ort und Orientierung



- lokale Merkmale
 - wavelet Koeffizienten: Frequenzen der Gesichtsmerkmale ('Kanten') wie z.B. Auge, Mund
- globale Anordnung der Merkmale
 - absolute Position der Frequenzen im Bild



Beispiel: Gesichtsdetektion

2. Aspekt: Trainingsdaten

▪ Positive Beispiele

- Sollten möglichst vielfältig sein
- Jedes Bild eines Gesichts wird manuell an den Rändern abgeschnitten und auf eine Standardgröße normalisiert (z.B. 19×19 Pixel)
- Es werden virtuelle Beispiele erstellt

▪ Negative Beispiele

- Beliebige Bilder, die kein Gesicht enthalten
- Teilbilder von großen Bildern



Beispiel: Gesichtsdetektion:

[Schneiderman and Kanade 98]



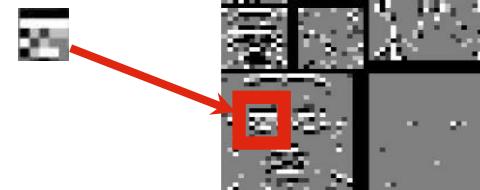
3. Aspekt: Klassifikator und Lernmethode

- Naïve Bayes Classifiers:

$$P(C_k|x_1, \dots, x_d) = \prod_{i=1}^d \frac{P(x_i|C_k)}{P(x_i)} P(C_k)$$

- Merkmale: x_i : Wavelet Koeffizienten f_i an bestimmter Position (u_i, v_i)

$$x_i = (f_i, u_i, v_i)$$



- 2 Klassenproblem:

- C_1 : Gesichter
- C_2 : alles andere = nicht-Gesichter



Beispiel: Gesichtsdetektion:

[Schneiderman and Kanade 98]

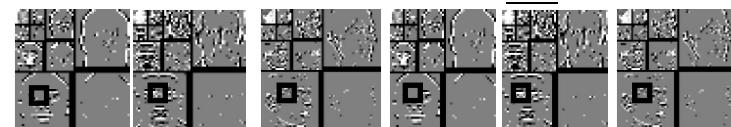


- “Lernen” = Schätze Wahrscheinlichkeit der Wavelet Koeffizienten für

- C_1 = Gesichter

$$P(x_i|C_1) = P(f_i, u_i, v_i|C_1)$$

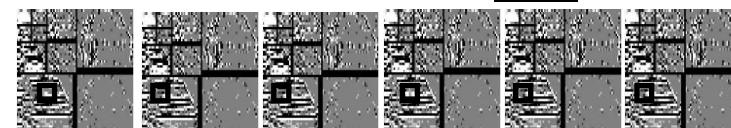
Wavelet Koeffizienten von Bildern MIT Gesichtern



- C_2 = nicht-Gesichter

$$P(x_i|C_2) = P(f_i, u_i, v_i|C_2)$$

Wavelet Koeffizienten von Bildern OHNE Gesichter



- Hier:

- Diskretisiere Koeffizienten und Positionen -> diskrete und endliche Anzahl von x_i
- Zähle, wie häufig jedes x_i in Bildern mit Gesichtern und Bildern ohne Gesichter vorkommt
- verwende Likelihood Ratio Test:

$$\prod_{i=1}^d \frac{P(x_i|C_1)}{P(x_i|C_2)} > \frac{P(C_2)}{P(C_1)} = \lambda$$

Appearance-Based Methods

Naïve Bayes Classifiers [Schneiderman and Kanade 98]



TECHNISCHE
UNIVERSITÄT
DARMSTADT

- Bilder aus verschiedenen Ansichten erkennen

- Mehrere Detektoren
- Jeder Detektor ist auf eine Ansicht spezialisiert: frontal, von links, von rechts



left profile
detector



frontal face
detector



right profile
detector



merged
detections

Appearance-Based Methods

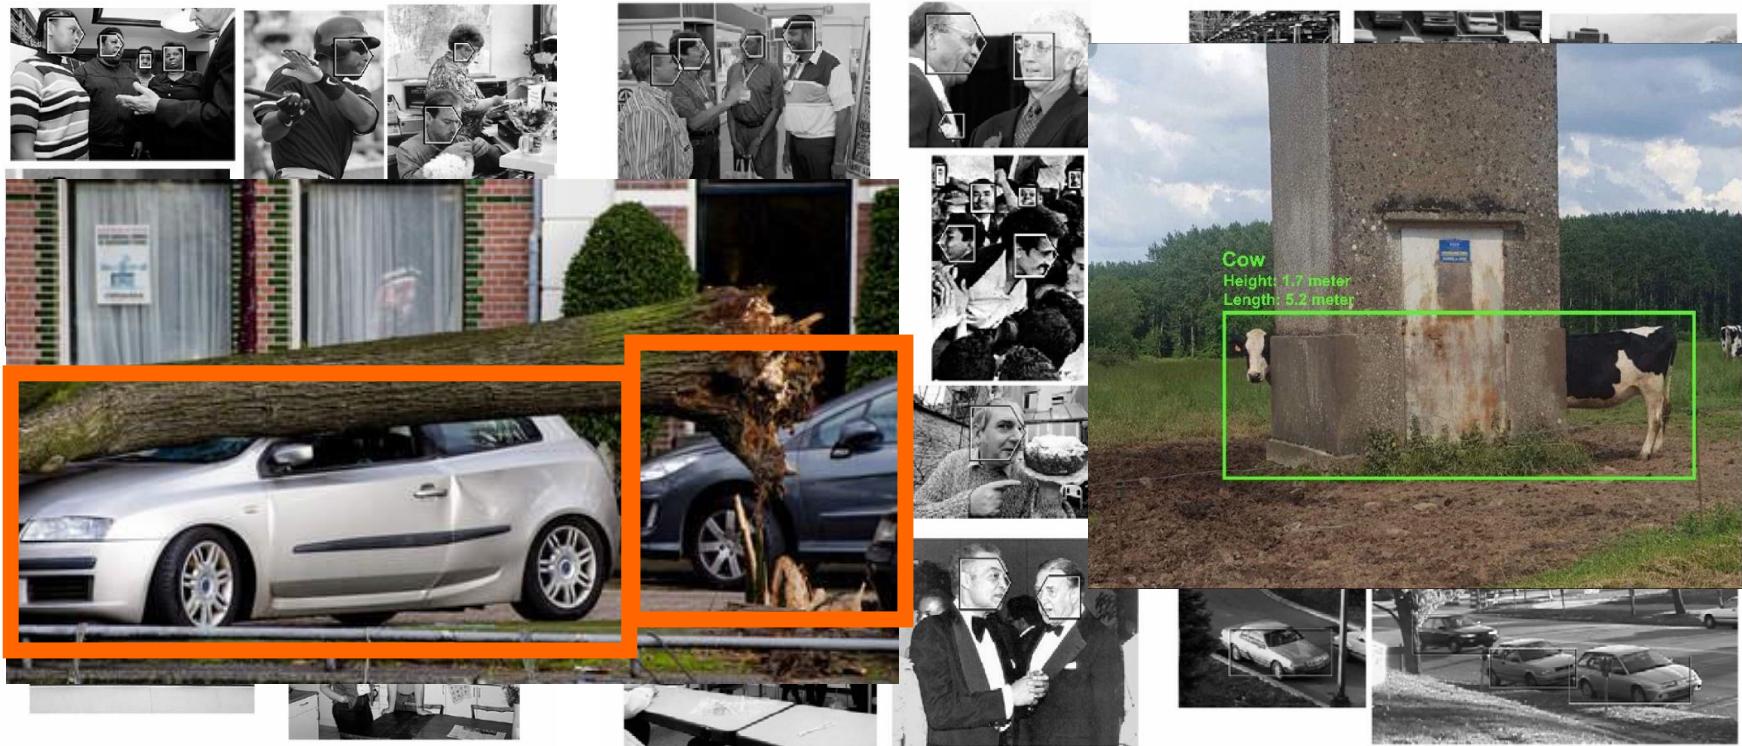
Naïve Bayes Classifiers [Schneiderman and Kanade 98]



▪ Testergebnisse



- Möglich, Gesichter aus verschiedenen Ansichten zu erkennen
- Erweiterbar, um Autos und andere Objekte zu erkennen



Koninginnedag 2012



TECHNISCHE
UNIVERSITÄT
DARMSTADT



Erkennung & Identifizierung



TECHNISCHE
UNIVERSITÄT
DARMSTADT

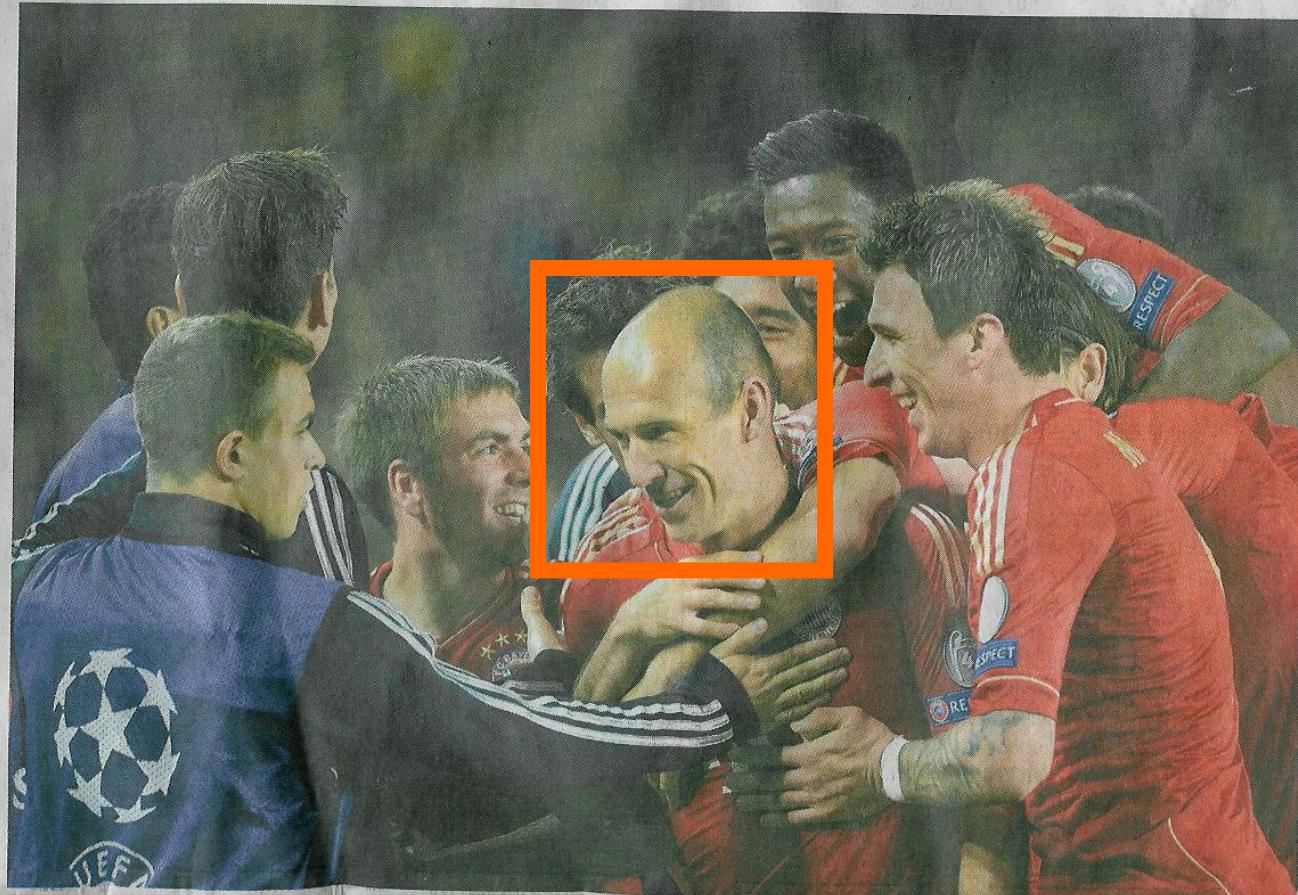


Donnerstag, 2. Mai 2013 · 1,50 Euro

Bayern und Dortmund im Champions-League-Finale

Der Pott geht in diesem Jahr auf jeden Fall nach Deutschland: Bayern München und Borussia Dortmund stehen im Finale der Champions League am 25. Mai im Londoner Wembley-Stadion. Im Halbfinal-Rückspiel beim FC Barcelona siegten die Münchener am Mittwochabend mit 3:0, nachdem sie bereits das Hinspiel mit 4:0 für sich entschieden hatten. Arjen Robben (auf dem Foto umringt von Mannschaftskameraden) und Thomas Müller erzielten die Tore, hinzu kam ein Eigentor von Gerard Piqué. Am Vortag hatte Dortmund bei Real Madrid in einem nervenaufreibenden Spiel zwar mit 0:2 verloren, doch reichte der 4:1-Sieg im Hinspiel für den Final-einzug. Mehr im Sportteil.

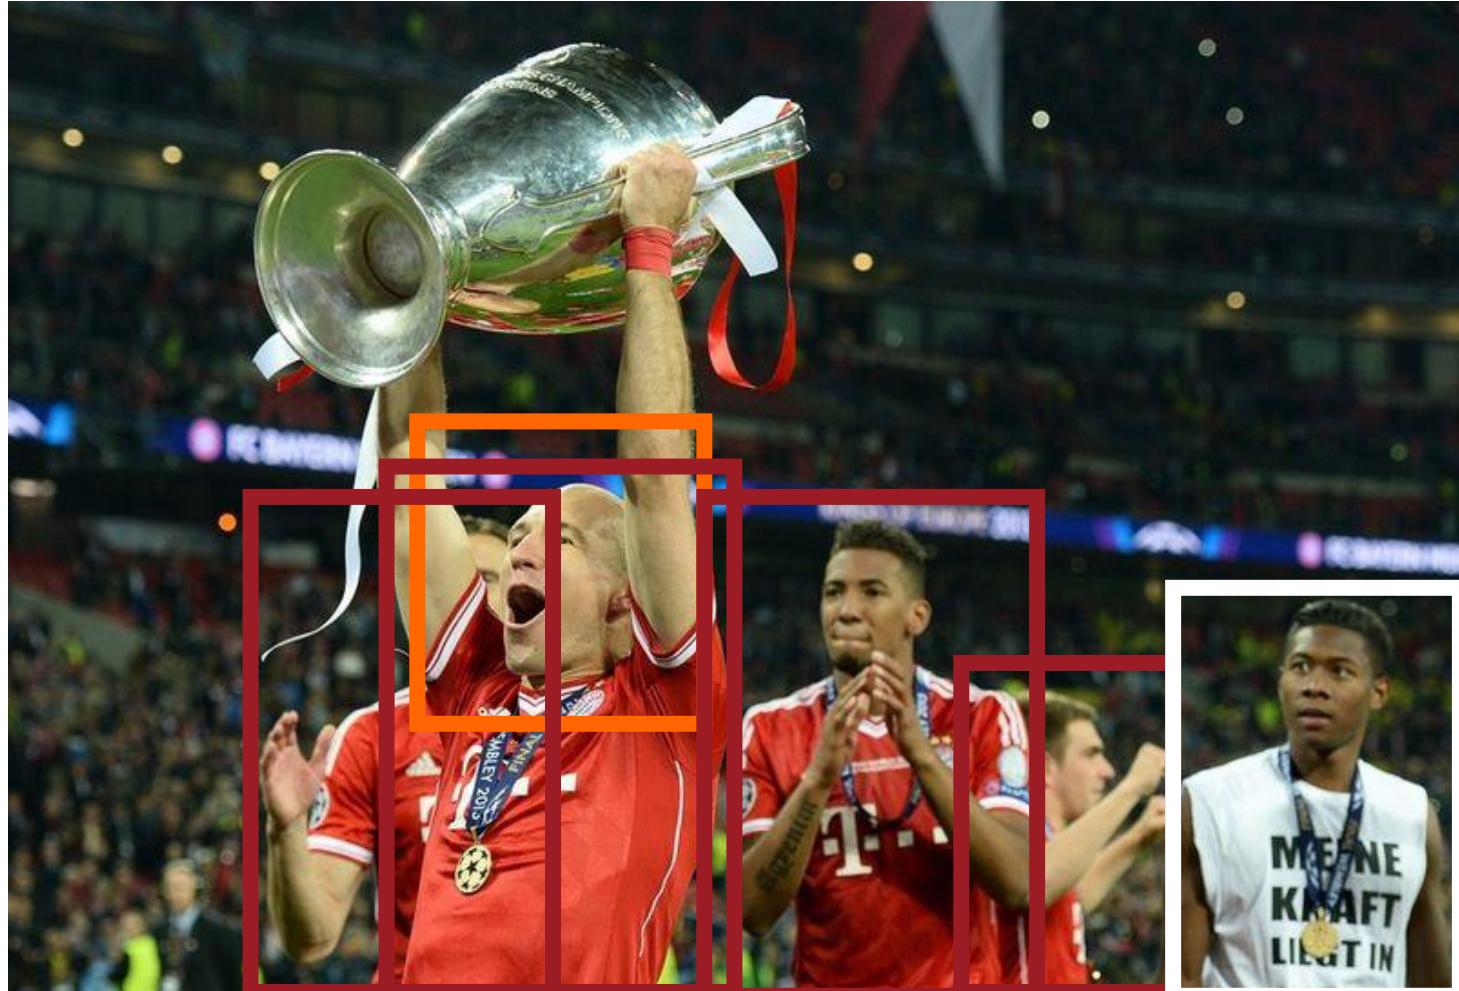
FOTO: DPA



Niederländer!

Bayern?!

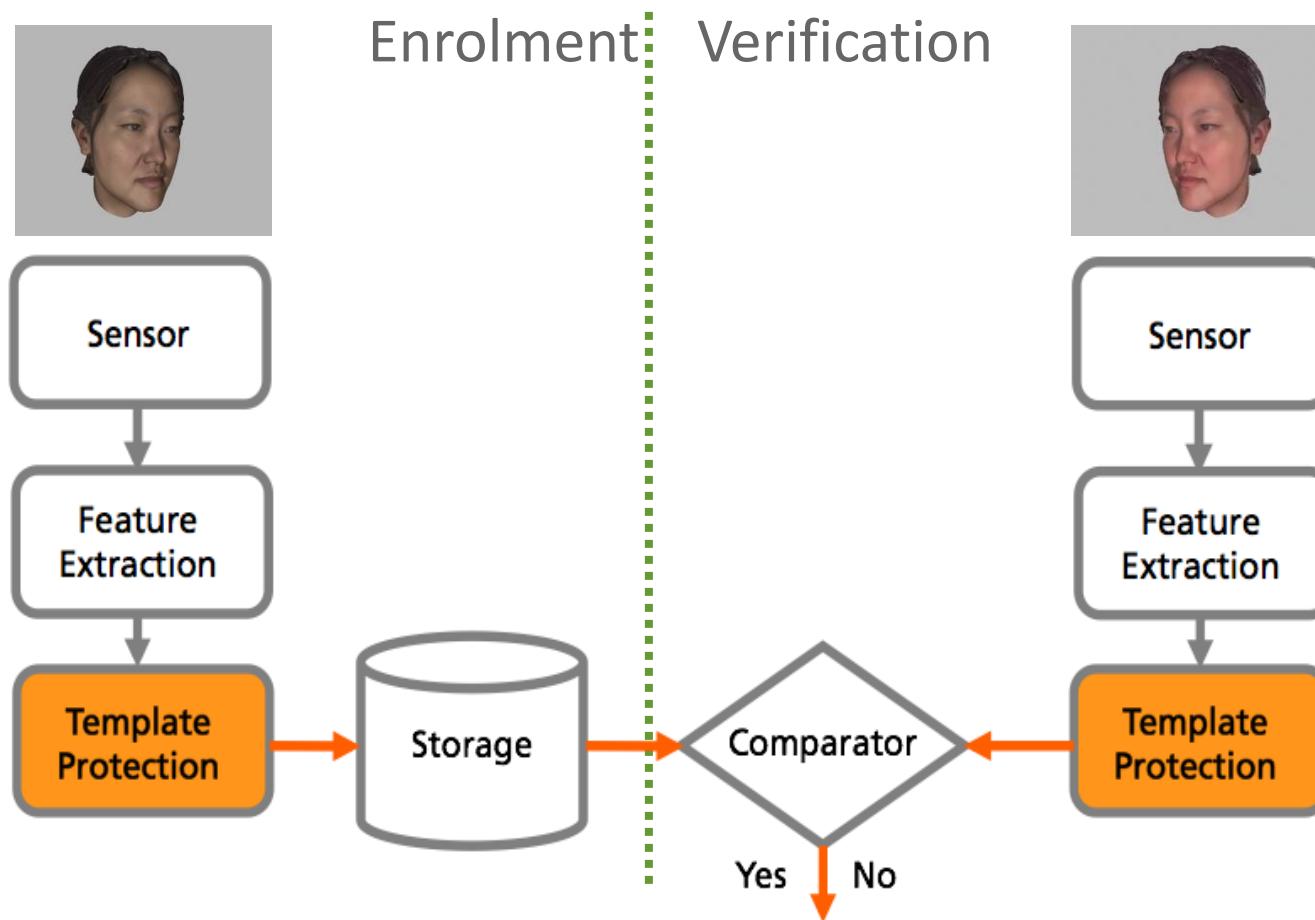
?!
!





- Gesichtserkennung zählt zu den biometrischen Verfahren.
 - Einsatzgebiete: sicherheitstechnisch, kriminalistisch und forensisch
 - Zweck: Identifikation oder Verifikation natürlicher Personen.
- Verifikation:
 - Die zu verifizierende Person muss dem System ihren Namen oder ihre User-ID mitteilen.
 - Danach entscheidet das [biometrische] System, ob die Person zum zugehörigen Referenzmerkmalsdatensatz gehört oder nicht. -> 1:1
- Identifikation:
 - Die zu erkennende Person offenbart ausschließlich ihr [biometrisches] Charakteristikum.
 - Das System ermittelt daraus durch Vergleich mit den Referenzmerkmalsdatensätzen aller Nutzer den zugehörigen Namen bzw. die User-ID. -> 1:n

Biometric Systems (with Template Protection)



Verifikation (1:1)



Input Data

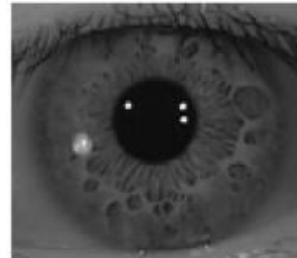
Database

Comparison-
Score

Decision

Probe

Ref



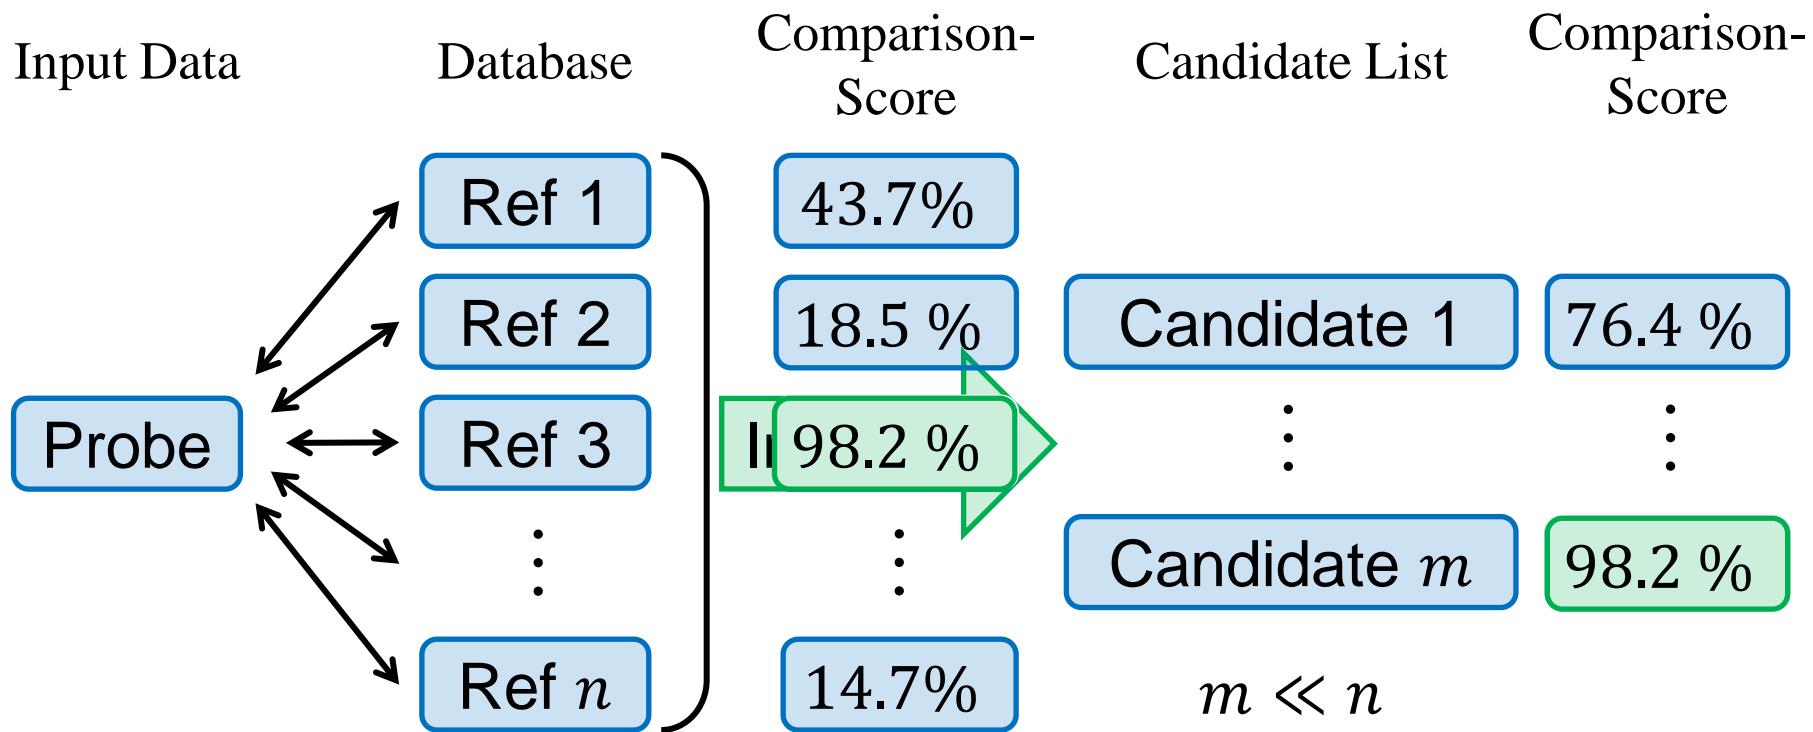
98.2 %

Threshold

True

(Genuine)

Identifikation (1:n)





Überblick

- Computer Vision
 - Objekterkennung und Objektdetektion als Fallbeispiel
 - Motivation heutiger Ansätze
- Bayes Decision Theory
 - Verwendung von Merkmalen zur Objekterkennung
 - Naive Bayes Klassifikator
- Gesichtsdetektion
 - Schneiderman & Kanade: Naive Bayes Klassifikator
de facto einer der erfolgreichsten Verfahren
 - Biometrie
- **Diskussion und Ausblick**

Diskussion und Ausblick



■ Objekterkennung

- lokale Merkmale UND deren Konstellation ist wichtig
- für die allgemeine Objekterkennung (nicht nur Gesichter) benötigt man häufig aufwändiger Modelle
 - Bestandteile sind aber im wesentlichen auch Merkmale und deren Konstellation
 - Beispiel: Detektion von Personen in Sequenzen von Bildern:



■ Weiterführende Veranstaltungen

- Computer Vision 1 & 2
- Statistical Machine Learning
- Biometrie
- Mensch- und Identitätsfokussiertes Maschinelles Lernen





Vielen Dank für die Aufmerksamkeit

(Und gleich zu den Übungen!)